

分类号: TP311
密 级: 公开

单位代码: 11407
学 号: 20187265



北方民族大学

专业学位论文

多模态领域知识图谱构建方法及应用研究

Research on Construction Method and Application of Multi-modal Domain Knowledge Graph

学 位 申 请 人: 刘昱然

指 导 教 师: 王海荣 副教授
邹新德 高级工程师

申请的学位门类: 工程硕士

专 业 名 称: 计算机技术

研 究 方 向: 大数据与知识工程

所 在 学 院: 计算机科学与工程学院

论 文 完 成 日 期: 2020 年 9 月

独创性声明

本人声明所呈交的论文是我个人在导师指导下进行的研究工作及取得的研究成果。尽我所知，除了文中特别加以标注和致谢的地方外，论文中不包含其他人已经发表或撰写过的研究成果，也不包含为获得北方民族大学或其它教育机构的学位或证书而使用过的材料。与我一同工作的同志对本研究所做的任何贡献均已论文中作了明确的说明并表示了谢意。

研究生签名：刘昱然

时间：2020年12月20日

关于论文使用授权的说明

本人完全了解北方民族大学有关保留、使用学位论文的规定，即：学校有权保留送交论文的复印件和磁盘，允许论文被查阅和借阅，可以采用影印、缩印或扫描等复制手段保存、汇编学位论文。同意北方民族大学可以用不同方式在不同媒体上发表、传播学位论文的全部或部分内容。

(保密的学位论文在解密后应遵守此协议)

研究生签名：刘昱然

时间：2020年12月20日

导师签名：刘昱然

时间：2020年12月20日

摘要

知识图谱（Knowledge Graph）作为知识组织和管理的有效模式，被广泛应用于知识检索、知识更新、问答等领域，其构建方法的研究受到了越来越多的关注。当前的图谱构建大多集中于文本单模态图谱，然而，图像、视频、音频等数据的大量涌现，使得多模态知识管理与表示的需求也更为迫切。因此，本文面向特定领域，整合多模态数据资源，应用实体抽取、关系抽取、数据融合和知识表示等构建方法，开展了多模态知识图谱的构建研究，具体研究成果如下：

（1）构造了多模态数据集。面向党建领域，从第三方平台获取了文本、图片、视频数据，使用 Python 中的 Jieba、Pandas、Numpy 等工具技术对数据进行了去重、去噪和归一化等处理，进而构造了多模态数据集；

（2）提出了标签对齐的多模态数据融合方法（LCSMMF）。基于已构建的多模态数据集，利用引入注意力机制的分段卷积神经网络（PCNN+ATT）抽取了文本语义标签，使用卷积神经网络（CNN）提取了图片语义标签，采用人工标注抽取了视频语义标签，调用最长公共子序列（LCS）算法实现了不同模态数据的标签相似度计算，通过比较选取相似度最高标签对进行链接，实现多模态数据融合；

（3）构建了多模态知识图谱。利用标签对齐的方法融合了多模态数据，并采用深度学习和人工干预等方法抽取数据中的实体及实体关系，根据抽取结果构建语义网络，实现了包含文本、图片、视频模态的党建知识图谱；

（4）开发了基于多模态知识库的智能导航实验系统。综合应用 neo4j、pycharm、Django 等技术方法，构建了 Windows 下运行的智能导航验证平台，为用户提供多模态党建知识图谱的展示、知识导航及语义检索等功能。

关键词：多模态知识图谱，标签对齐，知识融合，知识表示，信息抽取

Abstract

As an effective model of knowledge organization and management, Knowledge Graph is widely used in the fields of knowledge retrieval, knowledge update, question and answer, etc. The research on its construction method has attracted more and more attention. The current knowledge graph construction mostly focuses on text single-modal KG. However, the emergence of a large number of data such as images, videos, and audios makes the demand for multi-modal knowledge management and presentation more urgent. Therefore, this paper is oriented to a specific field, integrates multi-modal data resources, applies entity extraction, relationship extraction, data fusion, knowledge graph representation and other construction methods to carry out research on the construction of multi-modal knowledge graphs. The specific research results are as follows:

(1) Constructed a multi-modal data set. Facing the field of party building, we obtained text, picture, and video data from third-party platforms, and used Python tools such as Jieba, Pandas, Numpy and other tools to process the data such as deduplication, denoising, and normalization, and then construct a multi-modal State data set;

(2) A multi-modal data fusion method for label alignment is proposed. Based on the constructed multi-modal data set, the segmented convolutional neural network (PCNN+ATT) that introduces the attention mechanism is used to extract the semantic tags of the text, the convolutional neural network (CNN) is used to extract the semantic tags of the image, and the artificial annotation is used The video semantic tags are extracted, the longest common subsequence (LCS) algorithm is used to realize the calculation of the tag similarity of different modal data, and the tag pair with the highest similarity is selected through comparison to achieve multi-modal data fusion;

(3) Constructed a multi-modal knowledge graph. The method of label alignment is used to integrate multi-modal data, and deep learning and manual intervention are used to extract entities and entity relationships in the data, and a semantic network is constructed based on the extraction results to achieve party building knowledge including text, picture, and video modalities;

(4) Developed an intelligent navigation experimental system based on multi-modal knowledge base. Comprehensive application of neo4j, pycharm, Django and other technical methods to build an intelligent navigation verification platform running under Windows, providing users with multi-modal party building knowledge graph display, knowledge navigation and semantic retrieval functions.

Keywords: Multimodal knowledge graph, label alignment, knowledge fusion, knowledge representation, information extraction

目录

摘要..... I

Abstract.....II

第 1 章 绪论..... - 1 -

 1.1 课题研究的背景与意义..... - 1 -

 1.2 国内外研究现状..... - 1 -

 1.3 研究工作..... - 8 -

 1.4 论文组织结构..... - 9 -

第 2 章 相关理论与技术方法..... - 12 -

 2.1 相关理论..... - 12 -

 2.2 技术方法..... - 13 -

第 3 章 多模态数据的获取与处理..... - 22 -

 3.1 多模态数据的获取..... - 23 -

 3.2 文本数据的处理..... - 26 -

 3.3 图片数据的处理..... - 26 -

 3.4 视频数据的处理..... - 28 -

 3.4 PMD 多模态数据集..... - 31 -

 3.5 本章小结..... - 32 -

第 4 章 多模态党建知识图谱构建..... - 34 -

 4.1 构建流程..... 33

 4.2 SCHEMA 构建..... 33

 4.3 多模态知识抽取.....35

 4.4 多模态知识融合..... - 38 -

 4.5 标签对齐方法验证.....39

 4.6 图谱验证及存储.....42

 4.7 本章小结.....44

第 5 章 知识导航验证系统设计与实现.....45

 5.1 系统架构.....45

 5.2 系统开发工具及配置.....46

 5.2 功能模块设计.....48

 5.3 系统实现.....50

 5.4 系统功能测试.....53

 5.5 本章小结.....54

第 6 章 总结与展望.....55

 6.1 总结.....55

 6.2 展望.....55

参考文献.....	57
致谢.....	63
个人简介.....	64

第 1 章 绪论

1.1 课题研究的背景与意义

知识图谱(Knowledge Graph, KG)提供了一种高效的数据组织与管理模式,近年来已经成为热点研究问题,其相关技术和应用都取得了长足的进步。目前知识图谱构建的两种重要类型分别为开放领域知识图谱(General-purpose Knowledge Graph: GKG)构建和垂直领域知识图谱(Domain-specific Knowledge Graph: DKG)构建。开放领域知识图谱构建中的数据主要来自于各大知识库和搜索网站,采取自顶向下的方式构建,通过对百科知识的实体分析和抽取,最终得到可使用的开放知识网络,典型实例有 Wikidata^[1]、DBpedia^[2]以及 Knowledge Vault^[3]等。由于 GKG 的知识规模庞大、复杂度高等特点,在实际应用中往往难以满足用户的需要。垂直领域知识图谱的构建一般面向于一个具体方向,首先通过行业数据分析,确定抽取目标,选择抽取方式并将抽取结果用于构建大规模领域语义网络。典型的 DKG 有微软的学术知识图谱^[4]以及 Leetaru^[5]的地缘政治事件图谱等。在构建好的 DKG 中,由于知识间的专业相关性更强,联系更紧密,因此可以方便的实现图谱中的知识推理以及逻辑上的正确性验证。然而现有对于垂直领域知识图谱的构建研究大都集中于单模态图谱(如文本图谱、图片图谱等),忽略了音频、视频、图像等多模态数据在大数据时代的重要意义和多模态数据的重要特性,针对于大量多模态数据的图谱构建研究工作较少。

本文聚焦于领域多模态知识管理,开展了多模态知识图谱构建研究,构造了领域多模态数据集,提出了多种模态数据(文本、图像、视频)的融合模型,完成了面向特定领域的多模态知识图谱构建,并开发了相应的验证系统。本文提出的多模态融合理论框架对于解决多模态数据间的语义鸿沟等问题具有理论意义,可为相关研究工作提供参考模型;所构建的智能应用的实验系统对于智能检索、知识问答智能化具有现实意义。

1.2 国内外研究现状

知识图谱作为自然语言处理领域的新兴技术,备受研究者们的关注。上世纪 50 年代,计算机科学家首次提出了语义网络,用于自然语言中数据的存储。70 年代,研究者为了使语义网络和谓词逻辑可以相互替换表达,对二者的关系进行了深入研究^[6]。1998 年, Tim Berners-Lee 首次提出语义网^[7]这一概念,用于给万维网上的文档添加计算机可读的、可处理的语义“元数据”。2006 年, Tim Berners-Lee^[8]强调语义网的本质是要建立开放数据的链接。2012 年, Google 为了增强其

搜索能力,首次提出了知识图谱的概念,使得万维网由链接数据的网络逐步进化为链接知识的网络。知识图谱是多种数据的语义及其联系的联合表示,其实质类似于图状结构组织的数据库,在该结构中节点往往是实例、字面量、概念等,其中,实例、字面量以及概念之间的相互关系可以用图中节点之间的连边表示。知识图谱作为人工智能四大技术之一,已被成功应用在金融、教育、电子、物联网等领域,推进了相关领域智能化建设。国内外当前对于知识图谱构建的研究仍然在不断的推进,一些已被应用在相应领域的知名知识图谱如表 1-1 所示。

表 1-1 知名知识图谱

知识库	面向领域	构建方式	数据量	特性
Freebase	通用	手工构建	6800 万实例, 24 亿三元组	群体编辑的大规模多语言图谱
Clinga	地理		包含 50 多万中文地理实体	可以公开访问
Google Knowledge Graph	通用		5.8 亿个实体, 3.5 万个知识联系, 180 亿个三元组	数据来源于多种数据, 如 Freebase 及百科类数据库
Linked Movie Dataset	影视		61.5 万三元组数据	描述关于演员、电影等知识
影视双语知识图谱			23 个概念, 91 个属性, 70 余万个实体以及 1000 多万个三元组	融合 LinkedIMDB、百度百科、豆瓣等数据源
乳腺癌知识图谱			超过两千两百万三元组	集成乳腺癌相关知识, 包括乳腺癌相关临床试验数据、医学指南、电子病历、临床试验数据语义标注、医学文献等
医疗人工智能知识图谱	医学	以半结构化数据的抽取为构建基础	8 种器官, 20 余种疾病, 总共有 85 个实体	提供深度学习在医学影像分析中的应用的相关信息, 并提供基础问答功能
开源军事武器装备知识图谱	军事		武器类实体 5800 个, 实体属性关系 184 类, 实体上位关系 1 类	包括 8 大类、148 小类的武器装备, 涉及国家 88 个
DBpedia	通用		40 亿个实体, 2800 万个知识联系, 95 亿个三元组	包含多种语言的百科知识库
YAGO	通用		980 万个实体, 114 个知识联系, 4.5 亿个三元组	综合了 Wiki、Word Net、Geo Names7 等数据
Zhishi.me	通用		超 1200 万实例, 超 1.2 亿三元组	第一个大规模中文开放图谱
XLORE	通用		66 万实体, 5 万属性, 1000 万实例	大规模中英文双语百科图谱
NELL	通用	以非结构化数据的自动抽取为构建基础	8000 万个三元组	抽取过程中学习规则并迭代
Microsoft Concept Graph	通用		540 万概念, 1250 万实例, 8700 万上下位关系	从网页和搜索引擎中自动抽取知识

1.2.1 知识图谱构建方法

目前知识图谱的构建方式主要可分为完全的手工编辑、以半结构化数据的抽取为构建基础(如预先人工设定规则或正则,然后从半结构化的信息中再进行自动构建)和以非结构化数据的自动抽取为构建基础三种方式。

第一种方法是专家手工构建,这类图谱的构建主要通过手工方式,定义图谱中得实体机及关系。Douglas Lenat 在 1984 年创建了项目 Cyc^[9],Cyc 使用形式化的知识表示方法刻画知识,可以支持复杂的推理,但是过于形式化也导致知识库的扩展性和应用的灵活性不佳。普林斯顿大学设计的一种基于认知语言学的词典 Word Net^[10],它根据单词的含义组成一个单词的网络。2007 年, Metaweb 软件公司开发了一个由在线社区成员构建的大型协作知识库 Freebase,旨在创建一个能使人 and 计算机高效访问的全球公共信息资源。Freebase 使用图数据结构表示,节点表示实体,边表示实体之间的关系,并使用 graphd 三元组存储,使用 Metaweb Query Language(MQL)查询知识库中的知识。

第二种方法以半结构化数据的抽取为构建基础,例如利用在线百科类知识库进行抽取构建知识图谱。柏林自由大学、莱比锡大学和 Open Link Software 于 2007 年开始共同开发的 wikipedia 基金会的子项目 DBpedia^[11]从维基百科的词条中抽取结构化数据,并建立维基百科与其它数据集之间的连接。DBpedia 使用 RDF 表示抽取的信息共包含 30 亿条元组,其中 5.8 亿条源于英文维基百科,24.2 亿条源于其它语言的维基百科。2006 年,德国马克斯普朗克信息学研究所和巴黎高等电信学院共同开发了链接知识库 YAGO^[12],它的第一个版本主要从英文维基百科中抽取,并在 2008 年第一次升级,从此开始从信息框中抽取知识。2010 年,YAGO 开始抽取时间和地理信息元事实,在此基础上发布了 YAGO2^[13]。2015 年开始从 10 种不同的维基百科页面上抽取知识,发布了 YAGO3^[14]。YAGO3 集成了 Wikipedia, Word Net 和 Geonames 三个数据源的数据。国内的半自动化图谱构建研究中,清华大学、北京大学、中科院院自动化所、浙江大学、东南大学、复旦大学、华东理工大学、西安交通大学、苏州大学等单位共同创建的 Open KG,旨在培育开放的知识图谱社区和构建开放域的知识图谱。Open KG 包含了清华大学的开放百科知识图谱 XLORE、北京大学百科知识图谱 PKUBase、东南大学的百科知识图谱 Zhishi.Me、复旦大学开放百科 CN-DBpedia^[15]。CN-DBpedia 是复旦大学图数据管理实验室知识工场开发的项目,专注于各类大规模知识图谱构建、管理以及应用。CN-DBpedia 是一个大规模通用领域结构化百科,它主要从中文百科类网站文本页面中过滤、提取、融合信息,最终形成高质量的结构化数据。

第三类是以互联网网页数据为数据源,通过自动抽取技术获取大规模知识进行图谱构建。互

联网网页中富含大量的知识，这些知识的数量远远超过现有任何一个大规模知识库，且网页知识是时时刻刻保持更新，保证了知识具有很好的时效性。如何从网页获取高质量的知识是国内外研究者致力解决一个问题，很多研究机构均已经开发出自己的信息抽取系统。卡耐基梅隆大学的人工智能实验室 Tom Mitchell 教授为代表自主开发出一套信息抽取系统“永不停止的语言学习”（never-ending language learning, NELL）。NELL 是由四个 CPL, CSEAL, CMC, RL 抽取子系统从 Web 文本抽取知识，其中 CPL 是利用文本上下文进行知识抽取；CSEAL 抽取网页列表、表格等半结构化数据；CMC 采用逻辑回归模型对词语进行分类，基于词语形态特征进行知识抽取；RL 采用知识库已有知识推理出新的知识。2010 年至今，NELL 已经进行 1000 余次迭代抽取超过 5 千万条事实，每条知识是由实体、实体属性关系、属性值、迭代次数、可信度、数据来源六部分组成的。华盛顿大学以 Oren Etzioni 教授为代表自主开发出一套信息抽取系统 Text Runner，该项目命名为“开放信息抽取”（open information extraction, Open IE），该系统已经在 web 文本中抽取知识条目总数达到 5 亿条。

以上三种图谱构建的方式不同，会令图谱存在不同的优势和缺陷。利用人力手工进行知识图谱构建，可以得到较为完整精确的图谱，但人工的构建过程根据图谱规模的大小不同所耗费的人力时间成本不同，特别在大规模图谱构建过程中所需要的人力资源是工程领域中无法承受的。而在知识搜索网站的基础上，对其中的半结构化数据进行抽取从而构建的方式虽然最终得到的图谱不如手工构建图谱完善和准确，但该方法较人工构建而言，节约了大量的时间和人力资源，目前大多数知识图谱都是采用这种方法进行构建。另外一种构建方式为基于非结构化数据进行自动抽取，目前的自然语言处理技术达不到该方法的基本要求，因此该方法的图谱构建结果和前两种方法相比并不理想，但是基于非结构化文本进行抽取的方法的高自动化程度表明该方法在知识图谱未来的应用研究中具备极大潜力。

本研究所涉及的多模态图谱构建技术主要以半结构化数据的抽取为构建基础，具体构建技术包括多模态知识抽取、多模态知识融合、知识表示以及知识验证等。通过不同信息抽取技术，可以实现将来源非常广泛的多模异构数据进行实体、属性值及其关系的抽取。经过多模态数据融合，可以缩小从不同模态的数据中抽取的信息的歧义性，减少数据冗余，确保事实的准确性。下面将对以上几种构建技术分别进行阐述。

1.2.2 多模态知识抽取

多模态知识抽取的目标是给定多源异构数据，利用人工或机器学习、深度学习等自动化方式抽取出目标知识。人工抽取一般采用专家或者组织讨论的方式，所需要的人力资源较多。而自动

抽取依托于飞速发展的计算机技术，在近些年已经形成了许多成果，从早期的文本知识抽取发展为如今抽取图片、音频以及视频等具有模态多样性的数据。基于目前的研究现状，知识抽取方法可分为实体抽取、关系抽取和属性抽取。

实体抽取是指利用算法等手段将数据中的实体进行识别并从数据中抽取得到所需实体。Sun 等^[16]首次使用了文本数据和视图数据进行实体抽取。图片数据的处理过程中，利用已有的图像以及对应的文本数据组成数据对，最重要的是对文本数据进行预处理。由于视觉世界具有多样性以及自然语言具有复杂性，因此预处理的数据量非常庞大。进而利用该数据将无法辨识的冗余数据进行筛选，最终对数据进行分类整理并且将数据的语义相似度以及视觉相似度进行评比和判别。上述方法在许多语义标注研究中都表现出了较好的效果。Fang 等^[17]设计了一个模型，该模型能够利用已分类的图像数据构建实体，通过将文本数据和视觉数据进行聚类，利用最后所得到的解决确立视图概念。上述方法中主要涉及到三个概念分别是：概念搜索、关系提取以及分级建立。其中，概念搜索的过程中，首先根据百科网站中识别并且选出所需要的概念集合。针对所得到的结果，利用涉及到的标签图片进行学习从而得到训练模型，该方法能够利用对陌生图片的辨认不断更新实体。此外在概念关系提取的过程中，首先将无法直接提取的关系通过图像相似度进行抽取，进而就能够计算所求的类别关系。最后在分级建立过程中，提出了概念熵，将所得到的概念熵用于分析概念的语义广度中。上述模型可以对具有高冗余的噪声标签进行过滤和处理。最终综合文本数据和图像数据进行处理，能够更新图片和文本概念。Zhu 等^[18]在此之上通过构建多模态知识库结构，把图像数据和其对应的文本数据统一处理，将图像的特征和图像所对应的文本数据视作实体。因此能够将该知识库用在视觉知识问答等诸多热门领域，其优点在于知识库构建完成以后能够应对面向不同方向的多类别知识问答，省去了针对特定领域的知识问答而训练特殊的模型。

多模态数据里的不同类别的关系能够大致划分为同时出现和层级关系，一般来说，通用概念的使用频度比具体概念更高，因此，在关系抽取的过程中可以依据此现状计算实体文本数据和图像数据特征的统计现象。现有研究中，多模态属性抽取的主流方法往往把属性视为一类概念，从而能够利用与实体抽取中类似方法进行处理。Lu 等^[19]通过提取出陌生的实体、关系、属性中的特征，再将其运用到不同的数据处理模型中进行操作。2017 年，Ferrada 等人^[20]提出的 IMGpedia 从 Wikimedia Commons 数据集中的图像中收集大量的可视化信息，构建并生成了 1500 万个视觉内容描述符，图像之间有 4.5 亿个视觉相似关系。2019 年，Liu 等人^[21]将三个都包含丰富了数字文字和图像信息的知识图谱，通过 Same As 谓词将知识图谱中的实体连接在一起，并在不同的资源之间实现了关系推理。Wang 等人^[22]提出了多模态图谱 Richpedia，利用基于规则的关系抽取模

板, 借助 Wikipedia 图像描述中的超链接信息, 生成图像实体间的多模态语义关系。

1.2.3 多模态知识融合

多模态知识融合的目的是将来源、结构、表示方式不同的多源异构数据以相同的形式和组织结构映射到相同的框架中, 并通过使用合并和消除的方式处理知识库中重复、歧义及错误概念, 形成高质量的知识库^[23]。

多模态数据通过融合整合多模态的数据特征以得到一致、公共的模型输出^[24]。多模态融合能够利用多模态数据中的互补信息, 从而发现知识对多模态的依赖关系。现有的多模态数据融合方法可分为基于阶段的融合算法、基于特征的融合算法以及基于语义的融合算法^[25]。早期提出的基于阶段的融合方法主要策略是根据不同的数据融合阶段使用不同模态的数据完成数据融合, 因此该方法不要求将多模态数据映射到统一向量空间。基于特征的融合算法最早是指将从不同数据集中提取的特征顺序连接成一个特征向量, 然后基于串联后的特征完成聚类、分类、预测等任务。因此, 相关领域学者提出了一系列改进算法, 例如通过使用深度神经网络, 将多模态数据进行一致的特征表示^[26-27], 文献[28]中提出基于深度网络的多模态特征融合的基础模型, 表明跨模态数据的特征学习能够利用耦合的模态深度自动编码器完成。Srivastava 等^[29]为了融合图片数据和文本数据提出了多模态深度玻尔兹曼机模型。但由于多模态数据的表示方法和组织形式不同, 因此使用深度神经网络的多模态数据融合不能很好照顾到多模态数据的语义关联。而基于语义的多模态融合算法需要理解不同模态中数据的语义和不同模态之间的语义关系, 在融合过程中精准抽取不同模态数据的语义。目前, 基于语义的多模态融合算法主要有协同训练、多核学习、子空间学习、概率依赖和迁移学习方法^[30]。其中, 子空间学习方法基于数据多模态描述的语义共享, 且能够将多个高维特征集投影到同一低维语义相关空间缓解维度灾难问题, 因此受到越来越多学者们的关注。要解决不同模态数据之间的相关性, 关键是构造一个公共的特征子空间, 将不同模态的数据特征向量映射到该空间中, 然后在该空间上对不同模态的数据进行相似度度量。在语义融合研究早期, 多模态共享子空间学习算法利用典型相关分析^[31-33]使不同模态数据之间的相互关联性达到最大化, 在相关分析算法研究中针对数据非线性、非正交的问题, 之后研究者们通过利用深度学习的方法计算最大相关子空间, 最终能够得到所有的模态数据的投影矩阵, 提出了混合概率相关性分析^[34]、深度典型相关性分析^[35]等方法。Liang 等^[36]提出的方法设定跨模态时群组不变, 同时学习子空间投影和多模态间的联系, 该方法准确率较高。Mahadevan 等^[38]在学习低维嵌入过程中, 不改变模态数据内的局部结构, 极大地提升了低维嵌入过程中的稳定性。常用的子空间映射还有双线性模型^[39]、偏最小二乘法 (PLS)^[39-41]等。此外, 一些方法将所有模态知识映射到公共语义

空间中后,通过计算公共子空间中不同模态知识之间的语义相似度,可以对齐不同模态之间的实体,以便于表示。例如 Zhu 等人提出了联合知识嵌入方法来实现实体对齐,并基于迭代训练方法改进了对齐性能。该方法根据异构知识图的内部结构信息(实体和关系),首先使用 PTransE(基于路径的 TransE)分别学习不同知识图的分布式表示。把不同结构的知识图中的实体和关系映射到相同的低维语义空间中,并根据向量距离进行实体对齐。Lin 等^[42]表明在实体对齐过程中引入关系路径能够极大地提高知识图谱的构建质量。JAPE^[43]利用联合表示学习技术将不同知识图中的实体和关系映射到统一的向量空间中,将实体和关系的映射转换称为向量距离计算的问题。EnAli 是一种用于匹配两个或多个异构数据源中的实体的无监督方法。Li 等人^[44]构建了一个统一的融合框架,通过融合多个来源的情感知识来训练针对目标领域的特定领域的情感分类器。

在知识融合过程中,往往会产生一类现象,即出现两个或者两个以上的词语指向唯一一致的实体,为了解决此现象,研究者们提出了共指消解。知识融合过程中的另一类现象是出现一个词语同时可以代表两个或两个以上不同的实体,解决该问题的关键技术是利用聚类思想的实体消歧。其重点是计算实体和指标的相似度,实体与指标的相似度计算主流方法分为:空间向量模型,语义模型,社会网络模型以及百科知识模型^[45]。最近几年,实体消歧的相关理论和应用研究的进展都比较迅速。Xu 等人设计了基于长短期循环神经网络算法,并通过实验证明在实体消歧中,利用循环神经网络编码的效率更高。Xie 等^[46]基于实例相似性的聚类算法,提出了概念、属性和实体融合的三类模式;Gentile 等综合考虑了实体关联和语义网络进行实体消歧,通过基于维基百科网站数据进行的实验证明了该方法有较高的准确性。

1.2.4 多模态知识表示

在知识图谱构建前期,需要设定知识的表示形式,预先定义的知识表示关系到知识抽取和知识存储等操作的效率^[47]。

对于文本内容,现有的文本知识表示方法主要有基于符号逻辑的知识表示、基于语义网的知识表示^[48]。早期使用的方法大多是基于逻辑表示的表示方法,但这种方法对于规则编写要求较高,不适用于数据种类较多的场景。目前使用最为广泛和最具有认可度的知识表示方法是使用语义网的知识表示。语义网的知识表示使用的工具主要有可扩展标记语言 XML、描述 Web 资源的资源描述框架 RDF 和本体语义描述语言 OWL。其中,RDF 假定使用(若干个)三元组可以表示任何复杂的语义,由于它的结构定义清晰,数据不存在歧义,有助于知识之间的链接。因此,基于语义网的表示方法中 RDF 表示的应用在目前的使用中较多。而针对图像数据而言,由于图像数据和视频数据在数据抽取过程中将其统一转换为了特征向量,因此信息表示能够直接基于视觉特征,

而且能够利用因子图的形式表示所有特征进行知识表示^[49]。

1.2.5 知识验证

知识验证是为了对知识图谱的构建成果进行质量评估,度量知识的可信程度,去除可信度低的知识可以确保知识图谱的构建质量^[50]。

知识图谱构建是一个动态过程,需要及时加入新知识和更新动态知识,对已有知识图谱进行完善与补充。新知识获取方法往往采用信息抽取技术从多数据来源进行抽取,信息抽取系统抽取出的新知识往往存在一些错误,因此有关候选知识集的知识验证与可信度计算相关研究,引起国内外学者的广泛关注。国外的研究中, Cohen 等人率先考虑含有知识噪音的候选知识集构造出质量高的知识库; Jiang 等人^[51]提出基于 MLNS 模型对 NELL 系统抽取出的新知识进行验证,主要依据新知识中实体约束、知识来源可信度构建带有权重一阶逻辑规则实现知识验证; Namata 等人^[52]提出基于实体关系预测、集合分类来对候选知识集进行验证,然而他们构建一阶逻辑规则并未考虑本体约束对候选知识可信度的影响; Memory 等人^[53]提出构建概率软逻辑模型,选择可信度更高的知识集,他们的提出模型利用多源本体以及推理技术来推理出缺失实体关系; Benjamin^[54]提出一种基于贝叶斯方法的知识验证,主要解决面向多数据源知识融合时选取最正确知识问题; Zhao 等人^[55]提出一种基于贝叶斯概率图模型来计算真实可信度; Houping Xiao 等人^[56]提出一种新颖正确知识发现算法 ETCLBoot; 在国内,关于面向知识图谱构建的知识验证研究方法比较少,大多数研究都是面向所选数据源的知识融合技术,孙乐等人在全国知识图谱大会上提出知识验证这个概念,并阐述知识验证原理以及重要性,提出基于马尔科夫逻辑网模型可以解决知识验证问题。

1.3 研究工作

本文面向特定领域,深入研究了多模态知识图谱的构建技术与方法,针对多模态数据所具有的多源异构的特点,在目前关于多模态知识图谱构建的已有研究基础之上,将多模态数据的融合作为本研究中的核心内容,对于多模态知识图谱的构建进行研究。论文的研究内容主要包括:

(1) 多模态数据采集与处理。针对垂直领域多模态数据,使用第三方平台获取 Web 端的百科以及其他领域多模态数据,综合应用 Python 中的 Pandas、Numpy 工具包、采用人工干预和深度学习等方法对数据的格式和组织存储形式进行统一,去除碎片化数据等预处理操作。

(2) 多模态知识抽取。利用深度学习将文本数据进行关键词(实体、属性及属性值,以及实体间的关系)抽取,采用深度学习、人工标注等方式,将半结构化、非结构化的图片、视频数据进行语义标签提取,构建语义标签集。

(3) 多模态知识融合。利用最长公共子序列的语义相似度方法计算多模态标签集的标签相似度,选取置信度最高的文本对进行不同模态数据的融合。在已经构建好的多模态数据集上进行融合,并根据融合后的知识完成多模态党建知识图谱的构建。

(4) 系统验证。为了证明利用本文所提方法构建的多模态图谱具有模态丰富、准确性高、检索效率高等优势,本文在 Windows 系统中,使用 Python、Django 以及 D3、html、css 等工具技术搭建了基于知识库的智能导航验证平台,通过划分不同时期的节点并以导航形式呈现,最终通过实验结果证明了本文所提的方法精准度较高,构建的图谱较为丰富完善。

1.4 论文组织结构

本文内容的组织如下:

第一章 绪论。本章介绍了知识图谱的研究背景,针对现阶段知识图谱研究中的挑战和机遇,提出了本课题的研究背景和意义,并梳理了知识图谱构建中所涉及的相关理论和技术在国内外研究进展,最后,对全文的组织结构和内容进行了概括。

第二章 基础理论与技术方法。本章首先介绍了知识图谱的起源与发展等相关理论,接着分别对多模态知识图谱的构建流程与表示方式进行阐述,对构建流程中所涉及的相关技术和理论进行了分析说明。

第三章 多模态数据获取与处理。本章主要介绍了多模态领域知识图谱构建过程中不同模态数据来源,以及针对获取的原始单模态数据的语义特性及模态之间的语义联系等方面分别使用不同的数据预处理技术进行数据清洗与语义提取的详细过程。

第四章 多模态领域知识图谱的构建。在深入探究了领域知识图谱构建理论和相关技术后,对领域信息进行了细致分析,研究多种主流算法。之后总结了多模态党建知识图谱构建流程,并对流程中所涉及的具体方法和理论进行了详细阐述,最终实现了多模态领域知识图谱的构建。

第五章 基于多模态知识图谱的智能导航系统的设计与实现。本章搭建了党建知识图谱智能知识导航实验系统,系统主要包括知识导航、图谱可视化、语义搜索、知识卡片四个功能模块,证明了多模态知识图谱的表示形式相比单模态知识图谱更为丰富,可以为用户提供更好的信息化服务。

第六章 总结与展望。通过实验比对分析本文所提方法,总结了在多模态知识图谱构建中所存在的不足,并对其中具有提升空间的部分的后续改进做出了展望。

第 2 章 相关理论与技术方法

2.1 相关理论

2.1.1 知识图谱

语义网络^[57]作为知识的一种表示形式,利用网络中的节点表示了概念,节点之间的边用以表达概念间的相互关联,语义网络的优点在于直观上简单易懂并且对相似概念聚类也十分容易,但它无相应的节点和边的定义标准,并且难以实现不同模态的数据间的融合。Tim Berners Lee 先后提出了语义网 (Semantic Web) 和链接数据的概念,二者都可以用以表达资源与数据间的关联。Semantic Web 将网页中的数据变成了计算机能够理解的信息,其中 Semantic 使数据有了语义信息,Web 整合了一个包含海量信息的规模巨大的网络,其中的数据都包含着语义信息。基于语义网相关概念和技术,链接数据所考虑的重点在于不同数据集合中的关联。而 GOOGLE 公司 2012 年正式提出知识图谱至今,知识图谱的概念和相关技术仍然可以被视为语义网与链接数据的延伸。随着应用和技术的发展,关于知识图谱概念的定义至今仍然没有一个统一的标准,其中一种应用较为广泛和认可度较高的定义为:“利用图状结构组织和使用类型不相同的大规模数据的形式化的领域知识。”

定义 1 设 $E = \{e_1, e_2 \cdots e_{|E|}\}$ 是知识库中的实体集合,集合中的实体个数为 $|E|$; $R = \{r_1, r_2 \cdots r_{|R|}\}$ 是关系集合,集合中的关系个数为 $|R|$; 因此知识库中三元组集合记为 $S \subseteq E \times R \times E$, 则知识图谱表示为 $G = (E, R, S)$ 。

三元组的基本形式包括{实体 1、关系、实体 2}和{概念、属性、属性值}等,其中实体作为知识图谱构建中的基本元素之一,关系是指实体与实体间所存在的联系,并且它们在某种条件下有可能相同。概念可以是集合,类别,对象类型,事物类型,属性是实体特征的具体参数类型,如性别、年龄、国籍;属性值是参数类型的具体取值,如男性、21 岁、中华人民共和国。所有的实体都能够使用唯一的 ID 进行标识,所有的属性-属性值对能够表达实体的基本性质。

知识图谱根据针对领域的不同,大致可分为两类,即通用知识图谱和领域知识图谱:通用知识图谱的应用范围比较广,应用场景比较多,行业知识图谱应用范围比较狭窄,基本都是针对特定的领域。其中,构建通用知识图谱的重点在于包含内容的广泛性,往往不能够关于所有本体形成一个准确的定义^[58]。而领域知识图谱一般对特殊应用场景具有很强的针对性。领域知识图谱往往涉及行业中的特定任务关系和特定人物或者事件等属性。因此要求较高的完备性和形式化的准确定义,并能够确保实例所包含知识的深度和广度。领域知识图谱当前已经广泛应用于已交通运

输、医疗、情报、电子商务等行业中^[59]，为不同需求的用户提供了更人性化的精准信息服务。

2.1.2 知识图谱分类

早期的知识图谱构建研究主要聚焦于大规模知识的管理，即单模态图谱。单模态知识图谱是以单一模态进行知识表示的方法，虽然能在一定程度上对知识进行表示和描述，但是由于表示方法单一，因此缺失了知识的丰富性和多样性。一般来讲，单模态知识图谱分为以下两种类型：

文本知识图谱主要利用文本信息表示大量文本知识、并对文本知识进行推理演绎，主要的应用场景为语义检索、信息搜索、文本数据分析等^[60]。

图像知识图谱的研究重点为图像信息，其主要研究内容一般可以分为基于图像数据的特点进行的图像知识表示、知识抽取、知识存储等，但是图像知识图谱的构建中普遍具有难以获取实体、实体之间的相关性比较复杂，因此对关系进行建模十分困难等问题。主要应用场景是图片信息搜索、情感分析等。

然而单一的模态限制了知识的多样性与丰富性表示，随着近些年一些多模态视觉技术的提出，多模态知识图谱研究逐渐兴起。多模态知识图谱与传统知识图谱的主要区别是，传统知识图谱主要集中在研究文本和数据库的实体和关系，而多模态知识图谱则在传统知识图谱的基础上，构建了多种模态（例如视觉模态，音频模态等）的实体以及多种模态实体间的多模态语义关系。多模态知识图谱的应用场景十分广泛，多模态知识图谱不仅有利于为计算机图像、多媒体交互等领域的发展，对于跨领域的融合研究也有很大帮助。多模态数据虽然组成结构不同，但是在高层语义上表达的信息基本一致^[61]，因此研究多种模态数据的融合有利于推进语言表示等模型的发展，对于在语义层级构建多种模态下统一的语言表示模型提出数据支持。其次，成熟的多模态知识图谱技术可以为许多下游任务提供支持，例如，多模态融合技术可以广泛应用于以文搜图^[62]、新闻推送^[63]、购物推荐等场景中^[64]；多模态知识图谱补全技术可以通过远程监督补全知识图谱，利用动态更新完善现有的多模态知识图谱^[65]；多模态问答技术已经广泛应用与医疗、金融等领域^[66]，对于日常生活中问题解决有很大的实际意义。

2.2 技术方法

多模态知识图谱构建的构建过程中主要涉及知识抽取、知识融合、知识推理与补全，如图 2-1 所示：




图2-1 知识图谱技术框架图

本文所包含的架构主要分为四种核心技术，其中数据获取主要采用爬虫、下载、购买等方法技术进行数据采集，使用分词、去重、去噪等操作完成数据处理，多模态知识抽取主要采用机器学习的方法抽取出数据中的关键信息，多模态知识融合则需要对知识进行歧义消除、冲突检测等工作，实现图谱可视化及上层应用。

2.2.1 知识抽取技术

知识图谱主要包含的数据类型为结构化数据、半结构化数据和非结构化数据，其中多模态数据大部分都为半结构化数据，构建知识图谱首要工作是需要利用知识抽取技术从这些半结构化的数据提取知识，知识抽取中的一大重要下游任务是实体抽取，目前主流的实体抽取方法包括条件随机场模型(CRF-Model)^[67]、双向长短时记忆循环神经网络模型(BiLSTM)^[68]以及卷积神经网络(CNN)^[69-72]。

(1) 条件随机场

2001 年, Lafferty 等首次提出了鉴别式几率模型条件随机场模型(conditional random filed), 在 McCallum 后来将其运用于关系抽取领域, 若给定随机变量 X, 条件随机场模型能够输出随机变量 Y 的条件概率分布, 该分布能够构成马尔科夫随机场, 具体的形式化描述如定义 2 所示:

定义 2：设随机变量 X, Y ，则 $P = (X|Y)$ 为 Y 的条件概率分布。若随机变量 Y 能够构成马尔科夫随机场，则用无向图可以表示为：

$$P(Y_v|X, Y_w, w \neq v) = p(Y_v|X, Y_w, w \sim v) \quad (2-1)$$

若对于任意节点式 (2-1) 成立，则 $P = (X|Y)$ 是条件随机场，上式中：在图 $G=(V, E)$ 中，与节点 v 相连的所有节点 w 记为 $w \sim v$ ，而除了节点 v 之外的所有节点表示为 $w \neq v$ ， Y_v ， Y_w ， Y_u 为节点 v ， u ， w 的随机向量。

由于在实际应用中，一般会假设 X 和 Y 有相同的结构，即： $X = (X_1, X_2, \dots, X_n)$ ， $Y = (Y_1, Y_2, \dots, Y_n)$ ，但是在 CRF 的定义中缺乏对 X 和 Y 结构的约束，因此研究者们提出了线性链条件随机场 (linear-CRF)，弥补了这方面的不足。

定义 3：设 $X = (X_1, X_2, \dots, X_n)$ ， $Y = (Y_1, Y_2, \dots, Y_n)$ 均为随机变量序列，若 X 为给定随机变量序列，则 $P = (X|Y)$ 构成条件随机场：

$$P(Y_i|X, Y_1, Y_2, \dots, Y_n) = P(Y_i|X, Y_{i-1}, Y_{i+1}) \quad (2-2)$$

则 $P = (X|Y)$ 称为线性链条件随机场。

转移函数 $t_k(y_{i-1}, y_i, x, i)$ 和状态函数 $s_l(y_i, x, i)$ 分别为 CRF 中的两种特征函数。转移函数依赖于当前位置和前一个位置， $t_k(y_{i-1}, y_i, x, i)$ 为从位置 $i-1$ 的标记通过随机游走一步可以到达位置 i 上标记为 y_i 的概率。状态函数 $s_l(y_i, x, i)$ 在位置 i 中标记为 y_i 的概率。

设 $P = (X|Y)$ 为 CRF，当随机变量 X 的取值为 x ，那么随机变量 Y 取值为 y 的条件概率的参数化表达式如式(2-3)：

$$P(y|x) = \frac{1}{Z(x)} \exp \left(\sum_{i,k} \lambda_k t_k(\lambda_{i-1}, y_i, x, i) + \sum_{i,l} \mu_l s_l(y_i, x, i) \right) \quad (2-3)$$

其中

$$Z(x) = \sum_y \exp \left(\sum_{i,k} \lambda_k t_k(\lambda_{i-1}, y_i, x, i) + \sum_{i,l} \mu_l s_l(y_i, x, i) \right) \quad (2-4)$$

式(2-4)中， $Z(x)$ 为一个规范函数使表达式的值为概率值， λ_k 和 μ_l 为边上的权值， t_k 为节点之间连边的特征函数；而 s_l 为关于节点的特征函数。 t_k 和 s_l 为局部特征函数，二者的取值取决于节点的相对位置是否满足特征条件，若满足则值为 1，否则为 0。

CRF 模型在实体抽取工作中主要根据式(2-5)进行求解：

$$\operatorname{argmax} P = (y|x) \quad (2-5)$$

条件随机场的优点在于无需考虑序列的独立性、以及依赖于标签数据的影响，这样的性质显然可以符合自然语言的特性。并且通过序列化对全局参数进行优化的方法，能够很好地规避标记偏置，因此 CRF 模型在命名实体识别中的早期得到了广泛应用。

(2) 双向长短时记忆模型

递归神经网络 (RNN) 与神经网络的不同之处在于 RNN 可以以序列数据 (如具有语义的字符串、时间序列等) 作为输入, RNN 的记忆性表前后输出之间不是无关的。基于 RNN 这样的性质, 它经常用于带有时间顺序的相关问题的求解, 其网络结构如图 2-2 所示:




图2-2 循环神经网络

由图 2-2 可以看出, 循环神经网络中最基本的组成部分是隐藏层的神经元, 它是用于处理 RNN 中时序数据的关键结构, 但是对于网络深度大的循环神经网络进行训练的过程中, 网络层数的不断递增, 参数的变化将呈指数级别, 甚至可能发生梯度爆炸或者消失的现象。RNN 处理的数据集个数即为神经网络的层数。若数据集的规模较大就可能发生上述现象。对于梯度爆炸现象, 研究者们往往采取梯度修剪的策略。可是梯度消失现象的产生原理十分复杂, 为了解决梯度消失的问题, 研究者们提出了长短时记忆神经单元:

长短时记忆神经单元是通过对循环神经网络中神经元的连接方式进行了改进, 这种改进使有价值的历史信息可以被长期记忆, 防止因为网络结构过深引起的梯度消失。LSTM 神经单元的结构图如图 2-3 所示, 改进的地方在于增加了一个记忆单元 C_t 以及门控机制的使用, 分别为遗忘门 f_t , 输入门 i_t , 输出门 o_t , 用来选择和遗忘信息, 从而保留有价值的历史信息。




图2-3 LSTM神经单元

LSTM 的主要算法思想是：运用记忆单元 C_t 对上层输入信息进行甄别，传递对后续时刻有用的，遗忘无用信息，并输出当前时刻 t_i 的输出隐藏层状态 h_t ，如图 2-4 所示：




图2-4 LSTM计算过程

输入门的计算方法是在当前时刻的输入字 X_t ，在前一时刻输入隐藏状态为 h_{t-1} 。在计算激活函数之后，获得输出矢量 i_t 。 i_t 中的每个元素都在 0 到 1 之间。

输入门公式：

$$i_t = \sigma(W_i x_t + U_i h_{t-1} + b_i) \quad (2-6)$$

与输入门的计算方式类似，计算遗忘门 f_t 和输出门 o_t 的输入均为当前时刻的输入词 X_t 和前一时刻的隐藏层状态 h_{t-1} ，计算向量 f_t 以及 o_t ，从而计算 C_t 且输出 h_t 。

遗忘门公式：

$$f_t = \sigma(W_f x_t + U_f h_{t-1} + b_f) \quad (2-7)$$

输出门公式：

$$o_t = \sigma(W_o x_t + U_o h_{t-1} + b_o) \quad (2-8)$$

记忆单元及隐藏层公式：

$$c_t = f_t \odot c_{t-1} + i_t \odot \tanh(W_c x_t + U_c h_{t-1}) \quad (2-9)$$

$$h_t = o_t \odot \tanh(c_t) \quad (2-10)$$

其中 W 和 b 为模型中需要学习的超参数。

上述 RNN 网络结构为单向的，即信息只按某一特定方向进行传递，然而自然语言处理中经

常需要针对单个单词进行语义抽取,在该位置的单词语义不仅包含自己的语义,还会受到前后文的语义表达影响。但 RNN 中缺乏对下文信息的获取,为了解决这一问题,研究者们提出了许多改进模型,其中最典型的是双向循环神经网络(Bidirectional RNN, BiRNN)。BiRNN 可以分别考虑上文和下文中不同的语义关联,网络的输出即为考虑了前后文联系之后的结果。

BiRNN 表示双向循环神经网络结构中基本单元为 RNN 单元,基本单元同理也能够为 LSTM 单元,在应用领域,在需要进行自然语言处理的文本数据中基本单元为 LSTM 的双向循环神经网络的应用最为广泛。基本单元为 LSTM 的双向循环神经网络结构称为双向长短时记忆模型(Bidirectional LSTM, BiLSTM)。如图 2-5 所示,在 Bi-LSTM 网络中,将同一时刻的输入分别送入两个不同方向的 LSTM 结构中,通过网络模型进行计算,最终给出正向和逆向两种语义特征向量的拼接结果。




图2-5 双向长短时循环神经网络

(3) 分段卷积神经网络

由于在图像上的特征提取效果较优,Zeng 等提出利用卷积神经网络进行文本关系抽取的方法,文本关系抽取任务可以看作文本分类,抽取文档或句子的关键词作为特征,基于这些特征训练分类器并分类。目前,词嵌入技术在完整的句子中,难以获得两个在句子中相对位置较远的词语之间存在的关系,从而完整准确的体现整个子句的语义。针对这样的缺陷,相关研究者考虑使用 CNN 对句子进行特征提取。从而获得相对位置较远的词语之间存在的关系用以获取到整个句子的特征向量。

CNN 是一种多层神经网络,基本模型包含能接收多维数据的输入层、用于特征提取的卷积层、对卷积层的输出做进一步特征提取的池化层以及全连接层。应用在自然语言处理领域时,输入是一个映射为矩阵的句子序列,即一个二维数据。卷积层包含若干卷积内核,通过卷积操作提取局部特征以生成局部特征图。卷积核按照从左到右,从上到下的顺序滑动,每个窗口对应位置元素之和作为特征值。输出局部最优特征。池化操作的完整过程非常类似于降采样,其中最大池

化的利用最为频繁，不仅能够大大减少神经网络的计算复杂度，去除神经网络中不必要的部分，有效降低了过拟合的发生概率。而且，可以利用数据压缩去除数据冗余从而抽取出更为关键的特征。将池化层的输出结果用作全连接层的输入，并通过多层感知器降低维数，然后使用分类器进行分类，获得抽取结果。

2007 年 McDonald 等人^[19]证明了当句子的成分逐渐复杂，句子的规模逐渐增大时，传统的 CNN 的效率越来越低。但是句子成分复杂的长句式普遍存在于现实世界中，因此，研究者提出了分段卷积神经网络模型(PCNN)用于解决该现象。

PCNN 模型在卷积神经网络模型的基础上修改池化操作。在 CNN 中，max-pooling 层对整个卷积层的输出进行操作，对关系与实体的结构提取的效率不高，因此，分段卷积神经网络模型将卷积后的特征向量根据数据中实体在句子中的相对位置进行了两次划分，最大池化划分得到的三段数据，再对上一步所得结果进行维度相加，该方法能够极大程度解决句子长度较大对结果所造成的偏差。此外，分段卷积神经网络模型在训练过程中不再使用整个数据袋作为更新依据（因为每个数据袋中都是有噪声的，而且很多数据袋中的噪声示例远远多于正确示例），而是在训练过程中，依据 softmax 对每个数据袋中的示例进行条件概率评估。只选择其中概率最大的示例作为参数更新依据，很大程度上遏制了噪声对模型参数的影响。然而，改进后的神经网络仍然一些存在噪声数据，为了更好解决此问题，研究者们引入了注意力机制。

注意力机制起源于人类的观察视野内事物时的分配不同侧重的机制，注意力机制可以得到序列数据中与某个数据点显著相关的信息，从而优化输出质量。现在已经辅助了计算机许多智能领域发展，如计算机视觉、自然语言处理、语音合成等。注意力机制实现过程如图 2-6 所示。




图2-6 注意力机制实现过程图

注意力机制的基本原理是将 Source 看成是由一系列的<Key,Value>数据对组成的序列，对于给定的查询，使用注意力函数计算查询和每个键之间的相关性，再通过利用归一化函数计算所有

键的权值,并将该权值求和得到的值作为注意力值。即注意力机制的核心是对键值进行加权求和, Value 所使用的权重由 Query 和 Key 根据注意力函数计算得出,可以用公式表示为:

$$Attention(Query,Source) = \sum_{i=1}^{L_x} Simliarity(Query,Key_i) * Value_i \quad (2-11)$$

研究发现,在文本关系抽取中,通过引入注意力机制给句子赋予权重能够令神经网络在执行预测任务时可以将计算的重点放在核心位置。当解码器生成一个单词用于最终形成目标句子时,只有一小部分原始句子是与其相关的,因此基于内容的注意力机制用于基于原始句子动态生成加权上下文向量。网络将基于此上下文向量而不是固定长度的向量来预测单词。通过在学习过程中给予合理的关系实例较大的权重,有效增强了关系预测效果,对解决数据噪声有很大帮助。

2.2.2 知识融合技术

知识融合是实现知识共享的重要方法,其中,知识为利用网络中的海量数据里提取的多源异构信息,知识融合即将从网络中获取的这些知识通过各种检验,对知识进行判断和筛选操作,把通过验证的知识利用计算和对齐整合为数据库,知识融合的基础是知识抽取^[73]。知识融合的主要目标是对不同知识源的知识进行整合,使得实体信息更加丰富全面。不同于数据融合只关注未加工的原始信息,知识融合更关注的是有序的可用于指导实践的信息,即从不同模态中挖掘出的潜在语义^[74]。知识融合的重点在于确定知识的真值,链接正确知识对,消除知识理解的不确定性。

知识融合中,实体链接是指将从原始对象提取的实体对象链接到知识库中相应的正确实体对象的操作^[75]。其主要思想是根据给定的实体参考项从知识库中选择一组候选实体对象,然后通过相似度计算将参考项链连接到正确的实体对象。一般地,在进行实体链接操作之前,首先要保证数据质量,将原始数据进行归一化处理,以免影响最终精度,然后通过计算属性相似度、实体相似度等方法进行链接。本节将介绍几种主流的方法:

(1) 最小编辑距离(基于字符)计算属性相似度

最小编辑距离的思路为利用最少的编辑操作将原始字符串转换为目标字符串,转换过程中的操作次数即为编辑距离,具体转换方式如下:

$$D(i,j) = \min\{D(i-1,j) + 1, D(i,j-1) + 1, D(i-1,j-1) + 1\} \quad (2-12)$$

(2) 集合相似度计算相似度

Dice 系数用于度量两个集合的相似性,因为可以把字符串理解为一种集合,因此 Dice 距离也会用于度量字符串的相似性, Dice 系数定义方式如下:

$$sim_{\{Dice\}}(s,t) = \frac{2|S \cap T|}{|S| + |T|} \quad (2-13)$$

例如,计算两个字符串“学习时代楷模”和“向励志楷模学习”的相似度为 $2 * 4 / (6+7) = 0.62$ 。

然而, Dice 系数适用于集合间的相似度计算, 对于短文本数据, 研究者们提出了 Jaccard 系数, 定义如下:

$$sim_{\{Jaccard\}}(s, t) = \frac{|S \cap T|}{|S \cup T|} \quad (2-14)$$

Jaccard 系数的定义类似于与 Dice 系数, 而除了可以用符号分格单词外, 还可以考虑用 n-gram 分割单词, 用 n-gram 分割句子等来构建集合, 计算相似度。

(3) 最长公共子序列计算相似度

最长公共子序列是指, 给定两个序列 X 和 Y, 查询 X、Y 中所有公共子序列中最长的公共子序列, 可以通过应用最长公共子序列来量化序列的长度以计算相似度。最长的公共子序列求解方法包括穷举法和动态规划法, 但是当数据量达到一定数量后, 计算量会随着序列中元素数量的增加而呈指数增长, 而动态规划方法可以避免重复计算, 大大提高了运算效率, 因而成为了 LCS 的主要使用方法。

设序列 $X = (x_1, x_2, \dots, x_n)$ 和 $Y = (y_1, y_2, \dots, y_m)$, X、Y 的元素个数分别为 n 和 m; $X_i(x_1, x_2, \dots, x_n)$ 和 $Y_j(y_1, y_2, \dots, y_m)$ 分别为序列 X 和 Y 的子集, 其中, $i \leq n, j \leq m$ 。根据两个序列之间最长公共子序列的子集也是其公共子序列性质, 必须根据对应元素值是否相等, 递归求解最长公共子序列 $LCS(X_n, Y_m)$, 式 (2-16) 可表示具体计算过程:

$$LCS(X_n, Y_m) = \begin{cases} LCS(X_{n-1}, Y_{m-1}) + x_n, & x_n = y_m; \\ \max\{LCS(X_{n-1}, Y_m), LCS(X_n, Y_{m-1})\}, & x_n \neq y_m \end{cases} \quad (2-15)$$

如果求得的最长公共子序列长为 k, 文本 1 长为 n_1 , 文本 2 长为 n_2 , 则相似度 S 的计算公式为:

$$S = \frac{(2 * k)}{(n_1 + n_2)} \quad (2-16)$$

通过最长公共子序列算法进行相似度计算, 可以快速求出两个序列之间的最长公共子序列, 根据所求的结果度量序列间的相似度, 该方法具有较高的有效性。

第 3 章 多模态数据的获取与处理

本章针对于垂直领域，分析领域支撑的应用场景中包含的具体需求，深入研究了现有的数据获取方式，依据于需求制定了数据获取方案利用第三方平台进行文本、图片、视频等数据的收集，并对每种单模态数据的原始数据分别进行数据清洗和标注等处理，具体流程如图 3-1 所示：




图3-1 多模态数据处理流程

数据获取与处理的主要工作包括数据获取与处理以及数据存储。本研究主要集中在文本、视频和图像数据上，选取党建领域，针对多模态数据，使用第三方平台获取 Web 端的百科以及其他领域多模态数据，综合应用 Python 中的 Pandas、Numpy 工具包、采用人工干预和深度学习等技术方法对数据的格式和组织存储形式进行统一。

由于党建领域近年来发展速度快，随着无纸化办公的推进，涌现出大量多模态且组织性差的

数据，包括党建流程、党章党规等文本数据，人物以及重大事件的图片数据，大量人物生平记录以及史实记录视频，因此本文选取党建领域多模态数据，分析数据格式，完成数据的获取与处理工作。

3.1 多模态数据的获取

本节主要针对领域多模态数据，以党建领域为例，分析现有数据格式，构建网络爬虫程序，完成文本数据的获取工作。通过深入分析领域研究重点，确定了文本数据获取的主要来源渠道包括：领域性公开资料、百科数据如百度百科和维基百科等、领域类相关网站。以党建领域为例，主要的数据来源有中国共产党党章、中国共产党党史、百度百科、共产党员网、紫光阁、中国共产党新闻网等网站。与文本模态的数据相比，图片类型的数据更多涉及视觉方面信息，如纹理、颜色、大小、布局等，数据中的概念独立性较强，相关的分类标准以尺寸颜色为多，因此选择从百科图片类网站以及党建相关网站详情页等结构化程度及分类程度较高的网站获取图片数据。视频数据主要选取了共产党员网、百度百科分类页面下的部分人物生平及重大历史事件视频数据。

由于本文所需得多模态数据量较为庞大，常规处理手段无法在短时间内高效的获取大量数据，因此本文利用网络爬虫技术，分析页面请求，抓取所需要的数据，爬虫架构如图 3-2 所示：




图3-2 爬虫架构

根据 Beautiful Soup 无需正则表达式即可抽取网页、可以方便的对网页进行修改等优势，因此本节选择使用 Beautiful Soup 作为多模态数据爬虫的网页解析器，从现有的百科数据和其他网站上爬取领域多模态数据，具体的爬虫流程如图 3-3 所示：




图3-3 爬虫流程图

爬虫流程主要可以分为以下几步：

- (1) 准备工作：分析所需数据，挑选种子 URL；
- (2) 获取队列：将这些 URL 放入待抓取的 URL 队列；
- (3) 下载网页：取出待抓取的 URL，下载并存储进已下载网页库中。此外，将这些 URL 放入待抓取 URL 队列，进入下一循环；
- (4) 解析：分析已抓取队列中的 URL，并且将 URL 放入待抓取 URL 队列，从而进入下一循环；
- (5) 存储数据：将解析后的目标数据存储至本地；
- (6) 分析爬取是否完成，若完成则返回，否则继续进行 (2)。

其中，由于现在的大多数网站的主界面显示内容为所有图片页面的缩略图，其中包含原图的地址索引，访问原图地址需要通过访问缩略图的索引信息，针对大多数网页中所具有的如上特征，本文在图片数据爬取过程中，分析原图的索引页面地址虽然会因为图片的不同而不同，但该地址的改变呈现出一定规律，即只有图片的末尾数据位会改变。利用图片地址这样的特点，能够根据固定的地址位获取大量的图片索引页地址。利用 python 的第三方库可以通过缩略图索引获得原图的地址，利用 Python 特有的数据结构——列表可以按顺序依次存储图片地址，再利用网页请求读取

该列表的地址并将图片进行批量下载。

图 3-4-图 3-6 展示了爬取后的部分文本、图片、视频数据：

带你一次看懂二战历史系列之二，二战战前历史事件1926-1929
接着昨天，康穆妮斯缪斯将继续带各位小伙伴从1918年一战结束的历史一直讲述到1945二战结束。在这其中发生了许多有趣的事。包含军事冲突、外交折冲、政治角力及各式条约的签订等等，影响或导致第二次世界大战的一系列事件。让小伙伴们可以直观的看懂二战的历史。我们的文章将以年表的方式进行展现。同时也会为大家带来许多珍贵的历史图片供各位鉴赏。
1926年
1月3日潘加洛斯将军宣布自己是希腊的独裁者。
1月31日英国和比利时军队撤离德国科隆。
4月4日希腊独裁者潘加洛斯将军当选总统。
4月24日德国外交部长施特雷泽曼与苏联驻德大使尼古拉·克列斯京斯基，在柏林共同签署《柏林条约》，条约内重申德国与苏联于1922年所签订的《拉巴洛条约》，且未来五年内两国互不侵犯和中立条款。此举对波兰产生相当程度的威胁和冲击(导致波兰政变)；而欧洲各国认为可能会影响到德国在《罗加诺公约》中的义务，法国则担心在此背景下德国会加入国际联盟。
《日内瓦公约》第一部国际性质的法案*
5月12日至14日波兰元帅毕苏斯基，在首都华沙发动军事政变。
9月8日德国加入国际联盟。
12月25日日本大正天皇驾崩，皇太子裕仁亲王践祚，继位为天皇。
1927年
4月12日中国国民党中央常委蒋介石联合上海共进会及右派工人在上海的闸北、南市、浦东、吴淞等地，向上海总工会纠察队发起攻击，第二十六军第二师强解解除纠察队武装且搜捕中国共产党员和苏联委员；国共合作正式破裂，为国内战埋下了导火线。此举引发汪兆铭不满，导致宁汉一度分裂。
5月20日内志与汉志王国(即现代沙特阿拉伯的前身)与英国签署《吉达条约》，承认伊本·沙特拥有内志与汉志王国的主权，内志与汉志王国从英国独立。
6月7日苏联大使彼得·博伊科夫在波兰华沙遭到白俄流亡青年鲍里斯·卡维尔达的暗杀。
8月1日中国共产党中央总书记周恩来与国民革命军第九军副军长米德、第二十军军长贺龙和第十一军副军长叶挺等人率部起兵攻占南昌，就此中国共产党与中国国民党之间展开了长达十年的内战。
11月12日托洛斯基与李诺维耶夫遭到苏联共产党中央委员会投票决定开除党籍，随后中央政治局在第十五次代表大会上将其党羽悉数铲除。托洛斯基在这场和斯大林的路线斗争中败下阵来，而斯大林的权力则更加稳固。
1928年
5月3日至11日国民政府北伐军行经山东济南时与日军发生争执，导致双方在城内爆发激烈的武装冲突，特派山东交涉员蔡公时等人在山东

图3-4 部分文本数据爬取结果




图3-5 爬取后的部分图片数据




图3-6 爬取后的部分视频数据

从图中可以看出，网站爬取下来的原始数据结构相对较为复杂，数据中包含不规则字符和噪声数据，需要经过去重、去噪等处理，才能保证抽取效果。

3.2 文本数据的处理

由于文本数据来源较为广泛，不同网站包含丰富的数据格式，在爬取的过程中会出现缺失值、冗余信息、非定义字符等，即乱码以及噪声数据，这些数据会对文本知识抽取结果造成很大影响，所以本文使用文本分词、和文本清洗进行文本数据处理。

(1) 文本分词

在网页爬取的原始文本数据中，经常出现大段描述性文字，提取语义需要将长文本进行切分，由于现存的第三方库中 jieba 的词库较为丰富和完善，最终给出的分词结果较为符合实际，因此本文使用第三方库 jieba 结合垂直领域的词库进行分词的操作，最终结果为拆分后的词序列。

(2) 文本清洗

由于大多数情况下，获取的原始文本冗余部分较多，例如，获取的原始文本中会包含网页中的格式如 html、css 标签等数据，因此需要分步清洗，即对无用的标点符号、停用词等进行去除操作。由于 Python 中的函数可以方便快捷的完成数据清洗工作，所以本文主要调用 python 中的函数去除标点符号、数字归一化、利用停用词库和低频词库去除停用词、去除不必要的标签。

处理后的部分文本数据如图 3-7 所示：

新闻 绅士——陆铿
陆铿是华人新闻界最资深的老前辈，八十一岁的高龄却还站在第一线上。他精神矍铄、个性爽朗、对生命充满热情，七十八岁时还以惊人的记忆力，着手完成一生的回忆录与「忏悔录」。他不仅是台湾新闻界的奇迹，还是上一辈公认的绅士美男子。人的长相是会随着年纪与心境而转变的，许多朋友告诉我，我是年纪越大越好看，大家不晓得，我年轻的时候暴牙得厉害，但是现在不但暴牙都看不出来，连脸部的线条也都变柔和了。
认识我的人都知道，我一生中最爱两件事，第一是新闻，第二是女人。现在我已经八十几岁，回顾这两项我的最爱，都可以算过去，而我的心得是：不管想跑好新闻或得到女性的青睐，都要靠自己的「大格局」与「大气候」。记者不只是职业，它还应该是事业，投入这个无限宽广的天地，无论精神、工作、爱情，我都获得了实践与满足。
我记得于右任先生早年对年轻记者的鼓励，他说，做一个社会正义所期待的「无冕王」，除了要有冲劲与活力之外，最要紧的是谦虚，对每个人一视同仁，「说大人则藐之，勿视其巍巍然」，总统与清道夫有着一样的人格，应该被同等的对待。
有趣的是，谦虚的心态也可以用到男女的交往上。中国是个男性主导的社会，女人往往被视为附属的地位，对于这样的不公平，做为一个端正的男人更应该爱护、尊重女性，而体贴的心态可以从一些小动作中就可以表现出来，比如看到女性朋友有头发掉到肩膀上，你就不应该轻轻地帮她捡起来，丢掉、或放到自己的口袋里，这样的动作若是发自内心的诚恳，男性的魅力就会显现出来。
女孩子向你表示好感，不管她长得漂不漂亮、你喜不喜欢她，都应该同等地对待与尊重。我年轻时，她驻欧洲采访，曾经有一位英国的女性记者非常喜欢我，一次我驾车带她外出采访，不幸出了车祸，她严重骨折，虽然我对她没有男女感情的想法，但仍天天到医院陪她，事后她就对中国男性的体贴留下深刻的印象。
回顾我这一生，几乎从未在男女相处上碰过任何钉子，就是我对自己的感情保有像对事业一样的自我批判力，随时防止大男人主义的情形出现。
相貌是天生，但气度可以补其不足，甚至可以改变外貌，五四运动健将罗家伦就是有名的例子。罗家伦长相不佳，曾被讥笑是「一身猪狗熊」，但他学富五车，不但文笔优美，还曾任中国驻印度大使，他的夫人是人人称羡的美人，所以我说，「帅」最重要的是气度。

图3-7 部分文本数据处理结果

图 3-4 展示了部分经过去噪和分词的文本数据，经过上述操作的数据更易于进行知识抽取。

3.3 图片数据的处理

由于爬取的原始图片数据尺寸大小不同、格式不同，可能会在标签提取中出现梯度爆炸等问题，所以本节主要对已获取的领域图片数据进行预处理，并通过深度学习等方式对获取后的数据

进行去重、去噪处理，以保证抽取标签的准确性，接着利用神经网络模型提取图像的语义标签，便于进行图谱构建的下一步操作。

3.3.1 图片数据的预处理

本节主要对原始图像进行了尺寸的调整和归一化，其中主要的几种技术如下：

(1) 图片尺寸统一化，将原始图像缩放成指定的图像大小，本文图像大小尺寸统一设置为 600*800。

(2) 裁剪填充，本文图像的尺寸大小已经进行统一化，如果原始图像大于目标图像，则对原始图像进行裁剪操作，如果原始图像小于目标图像，则对图像拉伸过程中产生的空白像素点利用黑色像素进行填充。

(3) 调整图像比例（使用 `tf.image.central_crop` 等函数），调整了数据集中部分图像文件的长宽比，函数取值为 1，以中心点作为基准，将调整后的图像作为新的图像存储。

3.3.2 图片数据的标注

由于图片相对于文本含有更多视觉信息，如浅层的颜色、纹理，和较高层的语义信息如人物、动作等，因此本文使用深度学习模型结合人工校正提取图片语义标签。其中深度学习模型采用 Encoder-Decoder 结构，首先将图片输入，进入 Encoder 部分，经过 CNN 的空间特性，使用卷积层的 feature map，提取出图片 n 个位置的特征 $x = \{x_1, x_2, x_3, \dots, x_n\}, x_m \in R^D$ ，其中 x 是 D 维向量，例如，设置 feature map 的高、宽为 14，通道数为 256， $n=14*14=196$ ， $D=256$ 。同时，为了提取图像的高层语义，在解码时加入 Attention 机制，给提取的图像特征分配不同权重。

设在解码的第 t 阶段，即生成第 t 个单词时，传入 Decoder RNN 的上下文向量为 z_t ，RNN 前一阶段的隐藏层状态为 g_{t-1} 。这个上下文向量 z_t 就是 $x = \{x_1, x_2, x_3, \dots, x_n\}$ 的一个加权平均，具体地， z_t 和 $x = \{x_1, x_2, x_3, \dots, x_n\}$ 的关系可以用式 (3-1) 表达：

$$z_t = \sum_{m=1}^n \alpha_{t,m} x_m \quad (3-1)$$

其中， $\alpha_{t,m}$ 是衡量生成第 t 个单词时，第 m 个位置的图像特征所占的权重。这个权重实际是前一个隐藏层状态 g_{t-1} 和第 m 个位置图像特征 x_m 的函数。得到特征 z_t 作为 LSTM 的输入，经过隐变量生成，输出模型结果 y_t 。

上述模型较传统方法极大地提高了生成的语义标签准确率，但是由于监督数据较少，因此仍然会存在语义重心偏移、描述不详等问题，为了解决数据量问题对标签准确度造成的影响，采用人工干预，校准部分数据，提高了语义标签的精准度，最终得到图像语义标签 b 。

具体的提取流程如图 3-8 所示。




图3-8 图像语义标签提取

其中 I 是输入的彩色图像， $\{y_1, \dots, y_t, \dots, y_p\}$ 为“图像语义说明”，即该图片的语义标签，其中，最终输出的序列中单词数为其长度 p (p 的大小不定)。每个单词 y_t 是一个 K 维概率，用来表示该单词出现在图片语义中的概率，其中 k 为模型使用的文本词典的大小。 x_n 、 z_t 是 D 维特征，分别表示输入图像的 n 个不同描述区域和每个描述区域对应的上下文。

图3-9展示了经过语义标注处理后的部分人物图片数据。表格上方有搜索框，输入了“白崇禧”。表格列出了文件名、修改日期和文件类型。

名称	修改日期	类型
白崇禧	2020/4/4 11:18	JPG 文件
白崇禧.json	2020/5/4 12:40	JSON 文件
儿子 白先勇	2020/4/4 11:19	JPG 文件
儿子 白先勇.json	2020/5/4 12:38	JSON 文件
妻子 马佩璋	2020/4/4 11:18	JPG 文件
妻子 马佩璋.json	2020/5/4 12:39	JSON 文件
同学 吴石	2020/4/4 11:21	JPG 文件
同学 吴石.json	2020/5/4 12:39	JSON 文件
外甥 海竞强	2020/4/4 11:19	JPG 文件
外甥 海竞强.json	2020/5/4 12:39	JSON 文件
战友 张淦	2020/4/4 11:21	JPG 文件
战友 张淦.json	2020/5/4 12:40	JSON 文件
侄女 白韵琴	2020/4/4 11:20	JPG 文件
侄女 白韵琴.json	2020/5/4 12:36	JSON 文件

图3-9 图片数据及其语义标签示例

图 3-9 是经过语义标注处理后的部分人物图片数据，即人物与其亲属、朋友等人物图片，这些数据中不仅涵盖了图片标注过的数据，即每张图片都包含着该图片所表达的语义信息，而且为方便后续的数据处理，还根据这些语义信息生成了单独的标注信息文件。

3.4 视频数据的处理

本节主要针对领域视频数据，以党建领域为例，分析现有视频数据收集和处理的方法，根据其数据特性构建网络爬虫程序，获取相关视频数据，并对获取的视频数据进行去重去噪处理，接着利用深度学习和人工干预提取视频的语义标签，便于进行图谱构建的下一步操作。

3.4.1 视频数据的预处理

网络视频获取后依然存在格式不一、质量参差不齐等问题，因此需要进行处理保证数据的质量和一致性。其中，对数据进行的相关操作需要针对不同的应用需求，因此本文面向党建对爬取的视频信息进行了涉及数据清洗，同源性判定等操作。

(1) 视频数据清洗

视频数据清洗的最终目的是对多源异构视频数据进行统一化处理，避免由于视频格式、解码和视频解析等问题对后续的实验结果产生不良影响。为了对视频数据进行清洗，首先对数据的编码的格式、帧率、分辨率、码率等基本参数进行统一，本文使用的参数说明和一般取值如表 3-1 所示：

表 3-1 视频数据参数

参数	参数说明	一般取值
编码格式	压缩方式	H. 264、H. 265
帧率	视频每秒帧数	25fps、30fps
GOP I	帧周期	50
分辨率	视频的长、宽像素值	720P、1080P
码率	视频每秒比特数	Kbps

视频数据清洗的第二步是标准化视频流封装格式，本文选择将多种封装格式的视频转化成 MP4 格式。

(2) 视频同源性判定

由于网络上的公开视频所具有的开源性，因此，网络上大多数的公开视频不仅仅存在于一个视频网站中，这样的机制在对存储空间的一种极大浪费。爬虫系统虽然在爬取数据的过程中在一定程度上降低了数据重复，但是不能完全避免数据重复，数据重复有三种表现分别：①视频的基本内容和基本参数完全相同；②虽然视频的内容不完全一致，但是由于视频经过了简单的剪辑等操作处理因此内容上有较大的相似之处；③两个视频的内容虽然不一致，但是内容中存在相同的信息片段。视频的同源性判定技术仅仅在数据上提取视频的特征信息，而不将视频中展示的内容作为参考依据。本文通过计算视频文件哈希值判断视频文件同源性，若视频的哈希值相同，则视为视频同源，反之视频不同源。该方法速度快，准确性较高，能够用于去除重复视频文件。经过上述两步处理后的部分视频数据如图 3-10 所示：



图3-10 处理后的部分视频数据

3.4.2 视频数据的标注

为了便于后续构建图谱，视频数据以对应文本数据中的信息为依据进行语义标注。由于利用机器学习进行标注可以降低人工参与成本，效率更高，所以本文首先尝试采用机器学习的方法提取视频语义信息，但视频是由连续的图像序列组成，其中人物动作边界、重复的动作片段、事件的发生时序信息、帧之间的光流变化较为精细，需要提供大量的监督信息来指导模型训练，现有的研究以及方法对于视频语义信息提取工作的目标尚有较大差距，所得结果并不理想，误差将对多模态融合的最后结果产生非常大的影响，所得结果甚至将失去意义，而人工标注易于理解视频中的图像序列所表达的语义信息，基于视频的语义内容可将视频分类为人类行为和复杂事件等。最终根据文本标签规则对每个视频进行标注，标注主题可以最大程度上贴合视频内容、不遗漏视频中的动态信息。因此本文利用人工标注的方式提取视频标签，综合考虑了视频的重要帧及其中包含的语义信息，主要流程如图 3-11。




图3-11 视频语义标签提取

经过爬取及语义标注处理后的部分党建事件视频数据图 3-12 所示：




图3-12 视频数据示例

通过对多模态数据的收集与处理，得到了所需的文本、图片、视频多模态数据，形成了 PMD 多模态数据集。

3.4 PMD 多模态数据集

本章面向党建领域，利用 Python 分别从“人民网”、“共产党员网”、“每日经济网”、“中国共产党新闻网”等党建相关网站上下载及爬取了党章、党史、党规党纪等结构化数据以及先进人物、时政要闻等非结构化文本数据共 4000 条（txt 格式），从百度百科、百度图片、谷歌图片以及上述党建相关网站上爬取了重要会议、重大事件、党内主要人物生平等共 1800 条图片数据（统一为 jpg 格式），从豆瓣视频、爱奇艺、优酷、土豆等视频网站以及上述相关网站中选取了 1100 段影视视频资料（并统一为 MP4 格式）。经过筛选，形成了包含三种不同模态的数据集 PMD，其中数据集主要规模如表 3-2 所示：

表3-2 PMD数据集

数据类型 模态类型	人物	事件
文本	2872	1128
图像	1000	800
视频	790	310

3.5 本章小结

作为知识图谱构建中最基础和重要的工作，本节主要介绍了知识图谱构建中的多模态数据来源、采集策略以及处理方法。首先介绍了多模态数据的采集与处理的流程，其次按照不同模态数据结构特点分别对文本、图片和视频数据进行了详细阐述，即使用爬虫程序获取 Web 端的多种模态的党建数据，综合应用 Python 中的工具包、深度学习、人工干预等技术方法完成数据的去噪、去冗、清洗、分词、标注等预处理，将预处理后的不同模态数据依据文本进行标签提取，并展示部分结果，最终形成了 PMD 多模态数据集。

第 4 章 多模态党建知识图谱构建

本章在已构建的多模态数据集上，跟踪现有多模态图谱构建研究路线，面向特定领域，综合采用多种方法技术，完成了多模态知识图谱的构建。

4.1 构建流程

由于本文数据来源较广，数据模态丰富，因此在深入研究了多模态图谱的构建需求及构建技术后，选取党建领域，构建垂直领域多模态知识图谱，数据源为包含文本、图片、视频的百科类网站、党建相关网站等，综合利用了多模态知识图谱构建中的一些关键技术研究多模态党建知识图谱构建。相关技术方法如图 4-1 所示：




图4-1 多模态知识图谱技术路线

多模态党建知识图谱构建过程中的方法包含数据采集与处理、Schema 构建、多模态知识抽取、多模态知识融合、图谱可视化及图谱应用，其中，多模态知识融合使用的方法有计算相似度、标签对齐以及数据链接。

本文构建多模态党建知识图谱的数据基础是百度百科网站以及党建领域相关网站的文本、图片以及视频数据。如果直接使用这些多源异构的数据，那么由于数据的组织构成方式不同，并且其中存在一些不可用的碎片数据，因此后续的构建及应用将受到非常大的影响，所以对这些多源异构的数据首先要进行预处理，才能够保证后续过程的基本正确性。本文的第三章已经对数据采集与处理的过程做了详细阐述。

4.2 Schema 构建

通过构建 Schema，可以提炼出知识图谱中的知识，形成固定模式，依照该模式可以更好地服务于规范知识及后续的知识应用。知识图谱中的 Schema 构建相当于本体(Ontology)的建立过程，概念及其上下位、属性及其值、关系以及关系定义域(Domain)概念集构成了最基本的本体^[67]。随

着知识图谱领域研究的逐渐深入，已经有很多本体构建方法，其中七步法、骨架法、METHONTOLOGY 法、TOVE 法、IDEF5 法和 SENSUS 法是现存较为主流的方法。以生命周期而言，只有 METHONTOLOGY 法生命周期较为完整。根据其配套的相关技术完善程度对比，七步法和 METHONTOLOGY 法均优于其他几种方法。七步法、METHONTOLOGY 法及 IDEF5 法都详细阐述了方法的具体实现过程。除了上述区别，七步法构建方式为自动，其余方法大多需要人工构建。综上，本体构建方法中七步法和 METHONTOLOGY 法是两种。由于多模态领域数据是指针对某领域的多种异构数据，具有数据量大、类别丰富以及结构复杂等特点。在领域发展过程中会有海量的相关数据产生，然而其中只有少量数据有效可用，数据价值较低。同时，随着领域智能信息化，海量数据急速增长，构建 Schema 层能够有效地组织和管理领域数据。七步法用于构建本体已经较为成熟，然而七步法存在忽略内容更新的缺点，无法适应信息化时代的数据更新速度。METHONTOLOGY 通过在每一次计算之后对数据进行改进编辑从而对上述方法的缺陷进行了一定程度上的弥补。因此，本文将上述的方法都具备的优势进行合并从而搭建了 Schema 层，其过程如图 4-2:




图4-2 Schema构建流程

(1) 选取目标领域中本体信息

本文所提方法首先需要利用在互联网中公开的各种资源信息如报刊、论文等，抽象出党建领域的相关对象，了解党建相关人物、事件之间的关联关系，确定了构建本体的领域范围包括：党

建相关人物、重要事件和主要时间。

（2）分析复用该领域已有本体可能性

通过查阅调研，党建垂直领域暂无成熟的模型可以参考，因此本文 Schema 构建中不复用已有模型。

（3）获取领域知识

通过认真学习党史、党章等内容，日常生活中积累的时代人物和光辉事迹，结合查阅领域相关宣传网站，主要从百度百科及相关网站获取知识。

（4）确定领域核心概念

通过整理好获取的数据，分析文本数据并提取其中领域的核心概念。首次确定的概念可能会出现诸如语义重复和不规则表达之类的问题。针对这些问题，需要对相关概念再进行处理，消除概念的歧义。

（5）分析领域上下位关系

对于特定领域，数据往往所属不同层次，通过分析其上下位关系，可以更加明确领域数据的属性。例如，在上下位关系中，上位概念往往包含下位概念，但是上位概念所表示的内容一般比较广泛，下位概念则给出了更具体的实体概念。

（6）定义概念间属性及约束

在领域知识中仅定义类别和类别的层次结构不能完全表达领域知识，还需要通过约束刻画每种数据的特性。其中数据特性一般称为属性，包括对对象的特性描述与对数据的特性描述，对于对象的特性描述一般可以指两类对象之间的关系，例如人物和事件之间的关系；而数据属性则描述类本身特性，如人物的性别、年龄等。

通过构建 Schema 层，共得到了 4098 个命名实体，其中包括 862 个人物实体，659 个事件实体，496 个地点实体，2081 个时间实体。

4.3 多模态知识抽取

多模态知识抽取的目标是找到不同数据源获取的多模异构数据的关键性语义，并将这些关键语义以统一定义的方式表示。在上文数据获取与处理时已经对图片和视频数据的文本语义标签进行了抽取，同时上文通过 Schema 层的构建确定了知识抽取的关键词对，因此本节主要阐述通过已定义的 Schema 得到的文本数据的关键信息抽取过程。

在现有的知识抽取方法中，利用分段的卷积神经网络进行关键词抽取，能够提高特征向量表示的语义度，降低数据维度的稀疏性，有效解决数据噪声的问题。此外，对于输入的文本数据，

某些词可能会比其他部分包含更重要的语义信息，因此引入注意力机制关注重点信息，忽略无关信息，能够减少无关的信息对语义特征提取造成的干扰，使得模型提取出的关键信息更精准。基于此，本文使用引入注意力机制的分段卷积神经网络模型，对隐含在党建相关人物和事件数据中的关系进行抽取，提取原数据中重要的信息。将原始数据与需要提取出的目标实体一同输入模型进行抽取，抽取流程如图 4-3 所示。




图4-3 基于深度学习的关系抽取

其中本文用于抽取关系三元组的引入注意力机制的分段卷积神经网络模型如图 4-4 所示：




图4-4 PCNN+ATT模型

PCNN+ATT 模型抽取文本信息时，考虑文本中实体的位置信息，抽取准确率可达到 87.5%，抽取示例如：原始文本：“班主任周莉的儿子叫李帅，今年 9 岁了。”，抽取结果：“周莉，李帅，母子”；原始文本：“白可爱在法留学期间和周应军相识，之后他们之间便结下了友谊。”，抽取结果：“白可爱，周应军，朋友”。

该模型将语料中的词序列作为输入，通过 word2vec 的 Skip-gram 模型分别将单个词语表示成向量形式，与该词对应的位置向量进行拼接，通过卷积层提取到特征。池化层通过切分，将原始文本分为三段分别池化以更好的捕获两个实体间的结构化信息。最后，池化后的特征向量通过 softmax 层，得到的结果作为文本数据存入二维表中。如图 4-5 所示：

	A	B	C	D	E	F	G	H	I
1	中文名	国籍	民族	性别	出生地	出生日期	逝世日期	职业	毕业院校
2	傅某某	中华人民共和国	汉族	男	湖南省岳阳市平江县安定镇程家园村	1907年8月3日	1981年8月25日	军人	中共中央党校
3	赵某某	中华人民共和国	汉族	女	四川宜宾县北部白花乡伯阳寨村	1905年10月27日	1936年8月2日	军人	黄埔军校（六期）
4	项某	中华人民共和国	汉族	男	湖北武昌县（今武汉市江夏区）	1898年5月	1941年3月24日	军人	武昌涵三宫的日新预备学堂
5	张某某	中华人民共和国	汉族	女	浙江省浦江县	1910年	1979年2月12日		无
6	秦某某	中华人民共和国	汉族	女		1933年5月	2017年12月16日	教师	北京师范大学
7	邓某	中华人民共和国	汉族	男	广东省云浮市附城乡石塘村	1906年3月7日	1946年4月8日		
8	陈某某	中华人民共和国	汉族	女	广东番禺	1909年12月8日	1983年4月8日		
9	乌某某	中华人民共和国	蒙古族	男	内蒙古土默特左旗塔布村	1906年12月23日	1988年12月8日14时45分		
10	云某某	中华人民共和国	蒙古族	女	内蒙古土默特左旗	1923年			
11	乌某某	中华人民共和国	蒙古族	男	内蒙古土默特旗	1934年11月		科学家	
12	布某	中华人民共和国	蒙古族	男	内蒙古土默特旗	1926年3月	2017年5月5日	文学作家、公务员	延安民族学院
13	乌某	中华人民共和国	蒙古族	男	内蒙古呼和浩特市	1935年12月			苏联列宁格勒化工学院工程物理系

图4-5 抽取好的文本数据

从图 4-5 可以看出，抽取后的数据仍然包含噪声，如图中的绿色空白单元格，这些噪声影响了图谱构建的完整性和准确性，因此使用空值填充的方式去除噪声，将所有缺失值设置为“无”，去除噪声后的部分数据如图 4-6：

	A	B	C	D	E	F	G	H	I
1	中文名	国籍	民族	性别	出生地	出生日期	逝世日期	职业	毕业院校
2	傅某某	中华人民共和国	汉族	男	湖南省岳阳市平江县安定镇程家园村	1907年8月3日	1981年8月25日	军人	中共中央党校
3	赵某某	中华人民共和国	汉族	女	四川宜宾县北部白花乡伯阳寨村	1905年10月27日	1936年8月2日	军人	黄埔军校（六期）
4	项某	中华人民共和国	汉族	男	湖北武昌县（今武汉市江夏区）	1898年5月	1941年3月24日	军人	武昌涵三宫的日新预备学堂
5	张某某	中华人民共和国	汉族	女	浙江省浦江县	1910年	1979年2月12日		无
6	秦某某	中华人民共和国	汉族	女		1933年5月	2017年12月16日	教师	北京师范大学
7	邓某	中华人民共和国	汉族	男	广东省云浮市附城乡石塘村	1906年3月7日	1946年4月8日	无	无
8	陈某某	中华人民共和国	汉族	女	广东番禺	1909年12月8日	1983年4月8日	无	无
9	乌某某	中华人民共和国	蒙古族	男	内蒙古土默特左旗塔布村	1906年12月23日	1988年12月8日14时45分	无	无
10	云某某	中华人民共和国	蒙古族	女	内蒙古土默特左旗	1923年	无	无	无
11	乌某某	中华人民共和国	蒙古族	男	内蒙古土默特旗	1934年11月		科学家	无
12	布某	中华人民共和国	蒙古族	男	内蒙古土默特旗	1926年3月	2017年5月5日	文学作家、公务员	延安民族学院
13	乌某	中华人民共和国	蒙古族	男	内蒙古呼和浩特市	1935年12月	无	无	苏联列宁格勒化工学院工程物理系

图4-6 经过去噪的文本数据

经过去噪处理后的文本数据作为文本标签，供下文中文本、图像和视频标签对齐使用。

4. 4 多模态知识融合

通过前面的数据采集与处理工作可以分别得到文本、图像、视频三种模态的标签，为了实现多模态融合，本文提出了 LCSMMF 算法，利用不同模态的相同形式标签，通过相似度计算方法对不同模态进行融合，具体融合流程如图 4-7 所示：




图4-7 多模态数据融合流程

融合的基本思想为分别对文本、图片、视频数据进行语义标签抽取，将文本数据通过 PCNN+ATT 模型抽取出来党建相关的重要人物、事件及其关系与属性，将其作为文本语义标签规范存储在表中；将图片数据归一化处理，并使用 Encoder-Decoder 模型以抽取好的文本数据作为词典，提取出相关的图片语义标签集；视频数据使用人工标注的方式，根据文本抽取结果标注主题词，存储为视频标签集。输入获取的多模态数据集所对应的三类标签集，利用 LCS 算法查找不同模态文本标签中的最长公共子序列，计算三种模态标签的语义相似度，选择相似度最高的一组进行匹配，将该组标签中的图片、视频语义标签链接到对应文本上，输出对应数据对，具体处理方法如算法 1 所示：

算法 1: LCSMMF 知识融合算法

Input: $T=\{t_1, t_2, \dots, t_n\}$ 、 $I=\{i_1, i_2, \dots, i_n\}$ 、 $V=\{v_1, v_2, \dots, v_n\}$ // T 、 I 、 V 分别为文本数据集、 I 图片数据集、 V 视频数据集

Output: $E(a, i, v)$ // $E(a, i, v)$ 为融合后的数据对

- 1: $T_lable_set=A, I_lable_set=B, V_lable_set=C$,
- 2: $A=\{a_1, a_2, \dots, a_n\}$ 、 $B=\{b_1, b_2, \dots, b_n\}$ 、 $C=\{c_1, c_2, \dots, c_n\}$;
- 3: $commonset=Up(T, I, V)=A \& \& B \& \& C$; // 图片，文本，视频共有标签集
- 4: $value_T=v1x$, $value_I=v2y$, $lcs(v1x, v2y)=MAX(v1x, v2y)$ Call (2-16)
- 5: $label=\max(sim(d_1), sim(d_2), \dots, sim(d_i))$;
- 6: if $lable=T$
- 7: output $E(a, i, v)$
- 8: else
- 9: return None

其中，算法核心是多模态融合部分（算法第 3-5 行），以文本和视频数据的融合为例，设文本标签的值为 $T = v1x$ ，图片标签的值为 $I = v2y$ ，调用最长公共子序列算法计算出图片和文本标签的相似度 $sim(d_i)$ ，将所有标签对进行排序，选取相似度最高的一组标签进行链接。

4.5 标签对齐方法验证

文章所提出的 LCSMMF 算法作为多模态知识图谱构建中的知识融合技术，实现了文本、图像、视频模态数据的融合，为了进一步确保本文构建图谱的有效性，本节通过实验对 LCSMMF 算法进行了对比验证并对实验结果进行了分析。

4.5.1 实验环境

实验所使用的软硬件配置如表 4-1 所示。

表 4-1 实验环境

核心参数	值
内存大小	8GB
CPU 核数	4
网络带宽	10MB/S
操作系统	ubuntu16.04
Pycharm 版本	2015
Python 版本	3.6

同时实验为了处理图片、视频等模态信息，还使用了 skimage 数字图片处理库、Jieba 中文分词库、matplotlib 绘图库等依赖库。

4.5.2 实验流程

标签对齐的融合算法具体地实验过程如图 4-8 所示：




图4-8 实验流程图

(1) 抽取多模态数据标签

输入获取的多模态数据集，分别对文本、图片、视频数据进行语义标签抽取，将文本数据通过 PCNN+ATT 模型抽取出党建相关的重要人物、事件及其关系与属性，将其作为文本语义标签规范存储在表中；将图片数据归一化处理，并使用 Encoder-Decoder 模型以抽取好的文本数据作为词典，提取出相关的图片语义标签集；视频数据使用人工标注的方式，根据文本抽取结果标注主题词。

(2) 构建数据标签集

将各模态抽取出的文本标签进行汇总，分别存储为文本、图像、视频标签集。

(3) 计算相似度

计算三种模态标签的语义相似度，使用 LCS(Longest Common Subsequence)文本相似度算法，查找不同模态标签中的最长公共子序列并计算该组标签相似度。两个序列 X 和 Y 的公共子序列中，长度最长的那个，定义为 X 和 Y 的最长公共子序列，例如：一对标签中“十一国庆出行”与“十一国庆七天乐”的最长公共子序列为“十一国庆”。

(4) 相似度排序

将计算出的相似度进行从高到低的排序，选择相似度最高的一组文本标签进行匹配，将该组标签中的图片、视频语义标签链接到对应文本上，输出对应数据对。

4.5.3 实验结果及分析

LCSMMF 融合算法利用最长公共子序列的方法计算标签相似度，并进行对齐。本文选取了 AUC 和平均准确率 AP 两个常用指标在本文构建的 PMD 数据集上进行方法验证。

AP 指标对应 Precision-Recall 曲线下面积，能较好反映算法整体性能，其计算公式如式 (4-1)：

$$AP = \frac{TP}{TP + FP} \quad (4-1)$$

其中 TP 为正确对齐的多模态数据对，FP 为数据标签语义不相关的多模态数据对。

而 AUC 方法验证了链接对齐正确数据对的概率，设在实验中，共进行了 f 次对齐链接，其中，出现 f1 次实验结果为能够选择链接的数据对的次数，存在 f2 次实验结果为节点对得分相等或低于其中一个节点在 f1 中的某一次，AUC 可以表示为式 (4-2)：

$$AUC = \frac{f1 + 0.5f2}{f} \quad (4-2)$$

实验结果如表 4-2 所示：

表4-2 对齐方法验证结果

标签对齐方法	AUC (50%)	AP
CN	0.9122	0.9003
ACT	0.8909	0.8893
Node2Vec	0.9377	0.9136
Net2Vec-CLP	0.9223	0.9471
本文算法	0.9455	0.9733

实验使用标签对齐方法分别在本文构建的 PMD 数据集中的人物、事件 2 种分类上进行了计算，结果分别达到了 98.2%和 96.4%，平均准确率达到 97.3%。其中图片、视频类标签信息完整表述准确。实验结果表明，与其他方法相比，由于本方法使用了最长公共子序列两两计算相似度后再进行链接，综合利用多源异构数据的相同语义标签，并运用最长公共子序列的相似度算法计算标签集间的关联关系对齐多模态数据库库中的数据，一定程度上弥补了数据的“语义鸿沟”，而 Net2Vec-CLP 等都仅仅是使用网络链接的方式对语义信息进行建模，因此本文提出的基于标签对齐的多模态融合算法提升了准确率和 AUC 值，值得说明的是，相较于直接计算多模态语义特

征关联，本文使用的结构化文本作为语义标签得到结果更为精准，所以对准确率提升有很大帮助。

本文方法数据融合的结果如图 4-9 和图 4-10 所示：




图4-9 融合后的图片节点示例




图4-10 融合后的视频节点示例

图 4-9 和 4-10 展示了数据融合的结果，由于 python 无法直接读取视频和图片，因此本文使用序列化格式对图片和视频数据进行存储，结果证明了本文所提出的标签对齐方法的有效性。

4.6 图谱验证及存储

4.6.1 图谱规模

本章根据构建的多模态数据集，采用了多种方法，综合了多模态数据，形成了一个大规模的多模态知识图谱，其具体规格如表 4-3 所示。

表4-3 多模态党建知识图谱规模统计

知识图谱规模	数量	三元组总数
实体数目	4098	
对象属性总数	58	9889
数据属性总数	70	

本章构建的多模态知识图谱使用 RDF 形式进行表示，具体示例如图 4-11 和图 4-12 所示：

```
<?xml version="1.0" encoding="UTF-8"?><rdf:RDF
xmlns:ns1="http://www.MultimodalKnowledgeFusionAtlasofPartyBuilding.com#" xmlns:rdf="http://www.w3.org/1999/02/22-
rdf-syntax-ns#"> <rdf:Description rdf:about="http://www.MultimodalKnowledgeFusionAtlasofPartyBuilding.com#李淑清">
<ns1:人物id rdf:resource="http://www.MultimodalKnowledgeFusionAtlasofPartyBuilding.com#t00058"/> <ns1:职业
rdf:resource="http://www.MultimodalKnowledgeFusionAtlasofPartyBuilding.com#nan"/> <ns1:民族
rdf:resource="http://www.MultimodalKnowledgeFusionAtlasofPartyBuilding.com#汉族"/> <ns1:逝世日期
rdf:resource="http://www.MultimodalKnowledgeFusionAtlasofPartyBuilding.com#无"/> <ns1:image
rdf:resource="http://www.MultimodalKnowledgeFusionAtlasofPartyBuilding.com#李淑清.jpg"/> <ns1:出生地
rdf:resource="http://www.MultimodalKnowledgeFusionAtlasofPartyBuilding.com#无"/> <ns1:主要成就
rdf:resource="http://www.MultimodalKnowledgeFusionAtlasofPartyBuilding.com#无"/> <ns1:别名
rdf:resource="http://www.MultimodalKnowledgeFusionAtlasofPartyBuilding.com#李吉力"/> <ns1:性别
rdf:resource="http://www.MultimodalKnowledgeFusionAtlasofPartyBuilding.com#男"/> <ns1:国籍
rdf:resource="http://www.MultimodalKnowledgeFusionAtlasofPartyBuilding.com#中华人民共和国"/> <ns1:出生日期
rdf:resource="http://www.MultimodalKnowledgeFusionAtlasofPartyBuilding.com#1874年"/> <ns1:video
rdf:resource="http://www.MultimodalKnowledgeFusionAtlasofPartyBuilding.com#李淑清.mp4"/> <ns1:毕业院校
rdf:resource="http://www.MultimodalKnowledgeFusionAtlasofPartyBuilding.com#不详"/> <ns1:职业
rdf:resource="http://www.MultimodalKnowledgeFusionAtlasofPartyBuilding.com#无"/> </rdf:Description> <rdf:Description
rdf:about="http://www.MultimodalKnowledgeFusionAtlasofPartyBuilding.com#李莎"> <ns1:别名
rdf:resource="http://www.MultimodalKnowledgeFusionAtlasofPartyBuilding.com#无"/> <ns1:性别
rdf:resource="http://www.MultimodalKnowledgeFusionAtlasofPartyBuilding.com#女"/> <ns1:职业
rdf:resource="http://www.MultimodalKnowledgeFusionAtlasofPartyBuilding.com#教育家"/> <ns1:出生日期
rdf:resource="http://www.MultimodalKnowledgeFusionAtlasofPartyBuilding.com#1914年"/> <ns1:职业
rdf:resource="http://www.MultimodalKnowledgeFusionAtlasofPartyBuilding.com#nan"/> <ns1:民族
rdf:resource="http://www.MultimodalKnowledgeFusionAtlasofPartyBuilding.com#汉族"/> <ns1:毕业院校
rdf:resource="http://www.MultimodalKnowledgeFusionAtlasofPartyBuilding.com#莫斯科外语师范学院"/> <ns1:出生地
rdf:resource="http://www.MultimodalKnowledgeFusionAtlasofPartyBuilding.com#俄罗斯萨拉托夫州"/> <ns1:人物id
rdf:resource="http://www.MultimodalKnowledgeFusionAtlasofPartyBuilding.com#t00140"/> <ns1:国籍
rdf:resource="http://www.MultimodalKnowledgeFusionAtlasofPartyBuilding.com#中华人民共和国"/> <ns1:主要成就
```

图4-11 多模态图谱示例图

```
<rdf:Description rdf:about="http://www.MultimodalKnowledgeFusionAtlasofPartyBuilding.com#毛贻昌"> <ns1:职业
rdf:resource="http://www.MultimodalKnowledgeFusionAtlasofPartyBuilding.com#无"/> <ns1:出生地
rdf:resource="http://www.MultimodalKnowledgeFusionAtlasofPartyBuilding.com#湖南湘潭韶山冲"/> <ns1:人物id
rdf:resource="http://www.MultimodalKnowledgeFusionAtlasofPartyBuilding.com#t00052"/> <ns1:毕业院校
rdf:resource="http://www.MultimodalKnowledgeFusionAtlasofPartyBuilding.com#不详"/> <ns1:别名
rdf:resource="http://www.MultimodalKnowledgeFusionAtlasofPartyBuilding.com#毛顺生、毛良弼"/> <ns1:职业
rdf:resource="http://www.MultimodalKnowledgeFusionAtlasofPartyBuilding.com#nan"/> <ns1:性别
rdf:resource="http://www.MultimodalKnowledgeFusionAtlasofPartyBuilding.com#男"/> <ns1:image
rdf:resource="http://www.MultimodalKnowledgeFusionAtlasofPartyBuilding.com#毛贻昌.jpg"/> <ns1:主要成就
rdf:resource="http://www.MultimodalKnowledgeFusionAtlasofPartyBuilding.com#无"/> <ns1:video
rdf:resource="http://www.MultimodalKnowledgeFusionAtlasofPartyBuilding.com#毛贻昌.mp4"/> <ns1:出生日期
rdf:resource="http://www.MultimodalKnowledgeFusionAtlasofPartyBuilding.com#1870年10月15日（清同治九年庚午岁九月廿一）"/>
<ns1:民族 rdf:resource="http://www.MultimodalKnowledgeFusionAtlasofPartyBuilding.com#汉族"/> <ns1:逝世日期
rdf:resource="http://www.MultimodalKnowledgeFusionAtlasofPartyBuilding.com#1920年1月23日（民国九年己未岁十二月初三）"/>
<ns1:国籍 rdf:resource="http://www.MultimodalKnowledgeFusionAtlasofPartyBuilding.com#中华人民共和国"/>
</rdf:Description> <rdf:Description rdf:about="http://www.MultimodalKnowledgeFusionAtlasofPartyBuilding.com#连横">
<ns1:主要成就 rdf:resource="http://www.MultimodalKnowledgeFusionAtlasofPartyBuilding.com#台湾著名爱国诗人和史学家，被誉为“台湾文化第一人”。"/> <ns1:性别 rdf:resource="http://www.MultimodalKnowledgeFusionAtlasofPartyBuilding.com#男"/>
<ns1:video rdf:resource="http://www.MultimodalKnowledgeFusionAtlasofPartyBuilding.com#连横.mp4"/> <ns1:出生地
rdf:resource="http://www.MultimodalKnowledgeFusionAtlasofPartyBuilding.com#福建省漳州府龙溪县（今漳州龙海）"/> <ns1:
人物id rdf:resource="http://www.MultimodalKnowledgeFusionAtlasofPartyBuilding.com#nan"/> <ns1:民族
rdf:resource="http://www.MultimodalKnowledgeFusionAtlasofPartyBuilding.com#汉族"/> <ns1:职业
rdf:resource="http://www.MultimodalKnowledgeFusionAtlasofPartyBuilding.com#史学家、诗人"/> <ns1:image
rdf:resource="http://www.MultimodalKnowledgeFusionAtlasofPartyBuilding.com#连横.jpg"/> <ns1:出生日期
rdf:resource="http://www.MultimodalKnowledgeFusionAtlasofPartyBuilding.com#1878年2月17日"/> <ns1:国籍
rdf:resource="http://www.MultimodalKnowledgeFusionAtlasofPartyBuilding.com#中华人民共和国"/> <ns1:毕业院校
rdf:resource="http://www.MultimodalKnowledgeFusionAtlasofPartyBuilding.com#nan"/> <ns1:职业
rdf:resource="http://www.MultimodalKnowledgeFusionAtlasofPartyBuilding.com#nan"/> <ns1:逝世日期
```

图4-12 多模态图谱RDF节点示例图

对于融合后得到的多模态知识图谱，本文构建的图谱通过调用 **protégé** 进行关系合理化的推理，辅助领域专家进行了知识有效性的验证。

4.6.2 图谱存储

经过验证本文构建的知识不存在逻辑错误，为了保证后续的使用和更改方便，需要将其导入数据库中。一般的，对于知识图谱三元组，可使用的数据库有关系型数据库、RDF 三元组和图数据库^[69]。对于知识存储，关系型数据库采用将三元组转换为属性以及关系等二维表的方式，然而这种方法对自链接操作、数据量要求较高，对于不熟悉数据库操作以及对数据缺乏了解的使用者来说并不友好，可能会在其使用时出现查找和修改困难等问题；RDF 三元组一般用于语义网络中的资源描述，采用的时划分资源及其属性对的方式；图数据库不同于上面二者的结构，该类数据库利用图的形式进行数据存储，其数据模型中节点表示实体，节点之间的边表示实体和实体之间

的相互关系。由于图结构数据库的特性，它不仅可以巧妙地处理知识图谱中的数据对，还可以灵活设计数据库并根据数据量伸缩，即使需求发生变化，需要变更数据及属性，对于之前的数据进行操作时也不会出现问题。因此，本文构建的知识图谱选择使用图数据库进行知识存储。文献[50]的研究表明，目前主流的图数据库中，Neo4j 在大规模节点以及关系存储时的查询效率远远高于其他几种，因此 Neo4j 数据库得到了工业界的青睐。与此同时，Neo4j 的界面简单、操作便捷，对于不常使用数据库的领域用户友好，因此，本文利用 Neo4j 进行多模态知识图谱的存储，部分人物实体存储结果如图 4-13。




图4-13 Neo4j存储示例图

4.7 本章小结

本章首先对多模态知识图谱的构建过程进行了详细阐述，包括 Schema 层构建、多模态知识抽取、多模态知识融合的方法，最后介绍了知识图谱的存储方式。本文通过构建 Schema 层划分了党建领域所设计的关键概念、属性例如人物、事件、时间等及他们之间的关系，并将构建好的 Schema 层作为知识抽取的主要关键词。通过自顶向下以及自底向上相结合的模式，分步进行了多模态数据的标签抽取、标签对齐、数据链接、知识融合等操作。其中最重要的是多模态知识融合部分，通过提出的标签对齐算法，对多种模态数据的标签长度进行计算，并对齐和链接，实现了多模态融合。

第 5 章 知识导航验证系统设计与实现

5.1 系统架构

本章设计了基于多模态知识图谱的智能党建知识导航系统，作为针对本文所构建的多模态知识图谱的验证系统，能够有效证明本文构建的面向党建领域的多模态知识图谱具有高度可用性和准确性。系统在教育层面主要面向于想要了解党建相关领域知识的所有用户以及党建领域的相关人员。系统通过知识导航形式的呈现党建知识、展示知识图谱，通过语义搜索查询党建重大事件和主要人物等相关内容，可以让用户更清晰、直观地了解党建知识（如党建以来的人物、重要历史事件等），更好地为党建工作服务，对实现党建领域智能化发展具有实践意义。

智能党建知识导航架构如图 5-1 所示：




图5-1 智能党建知识导航架构图

该系统分为数据层，存储、查询和推理的技术层，管理用户和本体逻辑的应用层以及用于和用户交互的前端界面，具体地对每一层进行阐述：

（1）数据层

设计数据层的目的是为了给知识导航验证系统提供数据支持，也是系统能够正确运行的前提。本文数据主要来自百度百科、领域相关网站、相关文献等。若每次对数据库进行查询等操作都需要读取 RDF 文件，多次的重复读取操作会花费大量不必要的时间，而将数据上传至服务器进行

存储可以免去不必要地读取文件的操作。因此，在智能导航系统中将本文构建的 RDF 文件映射到图数据库中，以确保数据能够保存。

(2) 技术层

技术层引入 Jena 推理机制、查询语言、知识存储方法等，利用图数据库对数据进行读取、存储和查询等操作，并与前后台进行交互，进而实现知识推理与知识展示。

(3) 应用层

应用层可以通过用户管理和本体管理正确对应用户在系统中的角色，以确保用户的使用过程中不出现逻辑错误。

(4) 展示层

展示层主要的目的是通过网页的形式能够向用户直观地展示系统中所有功能模块，便于用户管理与使用，通过展示层，用户可以在系统内进行节点、关系的查询，也可以通过导航时间轴直观地了解感兴趣的内容。

5.2 系统开发工具及配置

5.2.1 开发环境

本文所搭建的基于多模态知识图谱的智能导航验证系统，使用的软硬件环境详细配置，如表 5-1 所示。

表 5-1 系统配置的软硬件环境

核心参数	值
操作系统	Windows
CPU	Intel(R)Core(TM)i7 CPU@3.4.0Hz
内存	8G
Python 版本	3.6
开发工具	Pycharm
Neo4j	3.5
可视化库	D3.js
浏览器	谷歌浏览器

5.2.2 开发技术

在系统开发中，本文参考了现有主流的开发技术，并针对多模态图谱，选取了 Neo4j 图数据库、D3.js 可视化类库等完成了智能导航验证开发。

Neo4j 是一个高性能的图形数据库，支持丰富的数据语义描述、并且兼具灵活性。它基于纯 Java 实现，支持大部分操作系统，部署便捷，具有 Java, JavaScript, Python, .Net 和 GO 等丰富的驱动语言支持，并且提供 C/C++, R, JDBC, Python 等各类语言驱动。提供面向图分析和模式匹配的 Cypher 查询语言，直观、简介、易于理解。Neo4j 同时也可以被看作一个高性能的图引擎，该引擎具有成熟数据库的所有特性，且由于它采用原生图(Native Graph)存储和处理数据，提供最优化的关系遍历执行效率，因此其连接速度比关系数据库中的表快上千倍。程序员工作在一个面向对象的、灵活的网络结构下而不是严格、静态的表中——但是他们可以享受到具备完全的事务特性、企业级的数据库的所有好处。Neo4j 中图形数据的结构如图 5-2 所示：




图5-2 图形数据结构图

如图 5-2 所示，在一个图中包含两种基本的数据类型，即 Nodes（节点）和 Relationships（关系）。Nodes 和 Relationships 包含 key/value 形式的属性。Nodes 通过 Relationships 所定义的关系相连起来，形成关系型网络结构。

D3（Data-Driven Documents）是一个关于数据驱动的文档的 java script 类库。D3.js 主要用于操作数据，通过使用 HTML、SVG、CSS 将数据转换为各种简单易懂的图形，是目前最流行的可视化库之一，被很多其他的表格插件所使用。它允许绑定任意数据到 DOM，然后将数据驱动转换应用到 Document 中。可以调用其用一个数组创建基本的 HMTL 表格，或是利用它的流体过渡和交互，用相似的数据创建 SVG 条形图等。本文利用 D3.js 实现图谱的多元化丰富展示。

5.2 功能模块设计

基于多模态党建知识图谱的知识导航系统中主要的应用模块如图 5-3 所示




图5-3 系统功能模块

知识导航系统的具体功能可分为：图谱可视化、知识导航、语义搜索和知识卡片，通过图谱可视化等技术能够方便用户利用简单操作查询党建相关知识。

（1）图谱可视化

图谱可视化模块的算法流程图如图 5-4 所示：




图5-4 图谱展示模块流程

通过链接后台图数据库，并动态加载图片以及视频实体，在页面中显示出多模态知识图谱。多模态知识图谱的展示有助于用户系统的了解党建领域的知识范围，从而提升用户对查询展示等功能的使用体验。

（2）知识导航

通过智能党建知识图谱，筛选抽取出重要节点（如重要时间、事件等节点），以时间轴的形

式实现知识导航，用户可以通过时间轴选择自己感兴趣的知识节点，实现党建领域的信息获取服务，其流程图如图 5-5 所示：




图5-5 知识导航流程

(3) 查询及展示

智能党建知识导航系统的查询功能可以允许用户对党建知识图谱中的相关词条进行直接查询，并且能够将用户查询到的信息以直观的可视化方式呈现给用户。可以让用户更为直观的获取知识。例如，搜索“南京事变”词条，可以查询到它的历史起源、事件经过、事件影响等，可以指导用户对从中获取所需资料，实现党建领域信息搜索服务，具体流程如图 5-6 所示。




图5-6 语义搜索流程

5.3 系统实现

基于上述规模的知识图谱，本文通过 Django 框架，利用 Python 语言开发智能党建知识导航系统。本系统开发环境为 Window 10，CPU 为 Intel(R) Core(TM) i5，3.40GHz，内存 16.00GB。Java 开发环境为 JDK1.7.9。主要利用 Python3.6 实现算法和相应功能。

前端界面使用 Django 框架进行编写，开发系统的 IDE 主要利用了 PyCharm，利用 Apache Jena Fuseki2 完成数据库。

本文构建的基于多模态知识图谱的党建知识导航系统可以实现党建相关人物、事件、时间等多方面展示，该实验系统主要包含的四个核心功能分别为：图谱可视化、知识导航、知识搜索和知识卡片。

（1）知识导航

智能党建知识导航系统的主界面即将党建中的重要节点进行筛选并按照时间轴的形式进行排序后展示，如图 5-6 所示。




图5-6 智能知识导航主界面

在系统首页展示出所构建的党建时间线，系统将党建四大时期分别进行展示，时间轴按照重大事件的发生顺序进行展示，通过知识导航，用户可以对党的发展历程有系统的了解，选中每个时间轴，在下方会呈现每个时期的重大事件合集。用户可以通过导航快速定位想要查找的党建知识，从而简化了搜索操作和时间。

（2）图谱可视化

系统的知识导航模块下方为图谱可视化，其展示结果如图 5-7 所示。




图5-7 图谱可视化界面

点击时间轴上的每个节点或搜索某一关键词可以进行该节点的相关图谱部分展示，即节点、节点属性值及相关关系节点的展示，用户可以选择自己感兴趣的节点进行点击，并展示和播放相关的图片和视频，通过可视化图谱，不仅全面展示了多模态图谱，还能挖掘用户的潜在兴趣。

（3）语义搜索及知识卡片

语义搜索框位于实验系统的上方，通过知识搜索模块，用户可以基于关键词进行精准的语义查询，输入目标关键词后，点击搜索按钮，系统将执行与数据库的交互，在数据库中进行遍历，返回输入的关键词相关知识给用户，为其提供优质的信息服务。

知识卡片模块为用户搜索的查询实体提供详细的结构化信息，位于二级页面中搜索栏下方。除此之外，下方的界面可以展示该搜索实体的属性、属性值等信息，并且以简明直观的方式体现。

展示界面如图 5-8、图 5-9 所示：




图5-8 语义搜索界面



图5-9 知识卡片界面

当查找到用户所查询的实体后，将该实体的关系及属性返回，并以表格的形式呈现，即为知识卡片界面。通过知识卡片，用户查询的节点展示更为直观。

本文构建的多模态党建知识图谱具有种类繁多的实体、属性值以及其关系等，并且准确性较高，功能比较完善。本文搭建的智能导航基于已构建的完整图谱充分利用了其中的优势为后续基于多模态知识图谱的上层应用开发提供了参考。

5.4 系统功能测试

在软件开发的周期中，软件测试作为重要的一部分对软件进行质量监管和保证，软件测试不仅可以重新检查软件的功能是否符合预期需求，还可以在其投入使用前检查出软件的逻辑是否存在问题，确保软件的逻辑正确性和可用性，以免影响软件后续投放和使用。软件测试方法主要包括静态测试和动态测试、功能测试、性能测试、黑盒测试和白盒测试等。本文对系统进行了非功能性测试和功能测试。

本节对系统的性能、安全、可靠性等方面进行了非功能性测试，测试结果如表 5-2 所示：

表 5-2 智能导航系统非功能性测试

测试方面	评估标准	测试结果
可用性	用户学习和使用系统的难易程度	高
兼容性	软件在特定的硬件平台上、不同的操纵系统平台	强
	上、不同的网络等环境中是否能够很友好的运行	
可维护性	投入使用后维护系统所需的工作量	高
可移植性	系统是否可以转置到不同计算机上	高

本文使用功能测试中的黑盒测试和白盒测试分别对系统的可行性以及逻辑正确性进行了验证。黑盒测试主要负责验证与用户的需求对比，开发的软件是否符合预期的功能。白盒测试需要对系统的功能进行验证，测试其是否可以正常运行，是否包含逻辑错误最初那个使用的方法为逻辑覆盖法。测试结果如表 5-3 所示：

表 5-3 智能导航系统模块测试

测试模块	测试方法	目标结果	测试结果
图谱可视化	打开首页，展示出多模态图谱	可以显示出多模态图谱的所有节点	通过
知识导航	首页点击，跳转至二级导航页面	为用户显示不同时间轴的信息	通过
语义搜索及知识卡片	输入查询关键字并点击查询按钮	显示出节点相关的部分图谱以及相关信息	通过

经过对智能导航验证系统进行功能测试与非功能性测试，系统的各模块功能均能够正常运行。网页响应时间较快，没有出现乱码等，智能导航验证系统满足了用户的需求，实现了基本功能并且界面清晰，各个功能简单，易于用户操作。

5.5 本章小结

本章主要介绍了智能党建知识导航系统的结构、设计与实现以及最终的测试部分。首先对基于多模态党建知识图谱的设计框架和总体的设计思路进行了阐述；并详细的解释了系统所具有的几个功能、如何实现相应功能以及实现该功能的目的；在系统实现部分，分别针对多模态党建知识图谱可视化与智能导航两个模块实现的细节进行了详细说明；在系统测试环节，对系统的各个功能进行了功能及逻辑测试。通过实验平台的搭建与测试，验证了本文构建的党建知识图谱的有效性与可用性。

第 6 章 总结与展望

6.1 总结

人工智能在数据时代的来临之后变得非常关键，而知识图谱作为人工智能中的重要部分，可以将知识规范化管理并组织通过其包含的各类实体和实体关系，引发了研究者们更多的关注。本文围绕目前特定领域的多模态知识表示和管理，开展了多模态知识图谱构建研究，通过数据获取与处理、Schema 构建、知识融合、知识表示、知识存储等技术构建了一个包含多种模态的知识图谱。本文主要做出了以下工作和贡献：

(1) 构建多模态知识图谱的 Schema：通过对党建领域的深层了解和深入分析，定义了党建知识图谱中最基本的实体概念，分别以“人物”、“事件”等实体为基础分析并提取了它们的属性，再根据现实中以上概念可能存在的关系来定义了语义关系。

(2) 多模态数据获取：本文根据领域知识图谱构建技术，选取特定领域，从不同数据源获取了文本、视频、图片数据，并对原始多模态数据进行清洗和归一化等处理，构造了多模态数据集。

(3) 多模态数据融合：本文利用对多源异构数据的知识抽取、知识融合和图谱嵌入等知识图谱构建过程中一般所能够使用到的关键技术，面向于党建领域中的党建文本、图片、视频数据，根据多源异构数据的结构特点，综合采用深度学习、人工干预的相关方法进行实体和关系以及语义标签抽取，并通过标签对齐实现了多模态融合，将不同模态数据进行链接，所形成的知识图谱对党建领域的知识组织、管理及应用提供有效支撑。

(4) 图谱验证：为了证明本文所提标签对齐的多模态数据融合方法的有效性以及利用该方法构建多模态图谱的可行性。搭建了智能党建知识导航平台，实现了智能导航、图谱可视化、语义搜索等功能，实验结果验证了本文构建的多模态党建知识图谱的有效性与可用性。

6.2 展望

本文在研究过程中遇到了以下问题：由于本文所构建的知识图谱只针对特定领域，且多模态数据收集较为繁琐，数据爬取过程比较复杂，容易出现错误和遗漏数据，所以要针对数据获取的方式以及数据量再进行进一步研究。其次，针对多模态数据的融合技术还有很大的研究空间。另外，本文开发的系统功能可以进一步完善，用户的页面友好性也可以进一步提升从而支撑基于党建领域知识图谱的智能化应用，如基于多模态知识图谱构建智能问答系统、多模态智能检索系统

等。

综上，本文研究仍需要进一步的改进和提升，未来将围绕以上问题进行研究。

参考文献

- [1] Vrandečić D, Krötzsch M. Wikidata: a free collaborative knowledgebase[J]. Communications of the Acm, 2014, 57(10):78-85.
- [2] Auer S, Bizer C, Kobilarov G, et al. Dbpedia: A nucleus for a web of open data[M]. The semantic web. Springer, Berlin, Heidelberg, 2007: 722-735.
- [3] Dong X, Gabrilovich E, Heitz G, et al. Knowledge vault[J]. 2014:601-610.
- [4] 奉国和, 梁晓婷. 国内推荐引擎学术研究知识图谱分析[J]. 情报科学, 2012, 030(001):144-148,160.
- [5] Leetaru K, Wang S, Cao G, et al. Mapping the global Twitter heartbeat: The geography of Twitter[J]. First Monday, 2013, 18(5).
- [6] Brachman R J. On the epistemological status of semantic networks[J]. associative networks, 1979.
- [7] Bernerslee T, Fischetti M. Weaving the web: the original design and ultimate destiny of the world wide web by its inventor[J]. IEEE Transactions on Professional Communication, 2002, 43(2):217-218.
- [8] Heath T, Bizer C. Linked Data: Evolving the Web into a Global Data Space[J]. Molecular Ecology, 2011, 11(2):670-684.
- [9] Lenat D B. CYC: A Large-Scale Investment in Knowledge Infrastructure[J]. Communications of the ACM, 1995, 38(11): 33-38.
- [10] Miller GA. WordNet: A lexical database for English. Communications of the ACM, 1995, 38(11): 39-41.
- [11] Auer S, Bizer C, Kobilarov G, et al. DBpedia: A nucleus for a web of open data. Proceedings of the Semantic Web, International Semantic Web Conference, Asian Semantic Web Conference, ISWC 2007+Aswc 2007. Busan, Korea. 2007. 722-735.
- [12] Suchanek FM, Kasneci G, Weikum G. YAGO: A large ontology from wikipedia and WordNet. Journal of Web Semantics, 2008, 6(3): 203-217.
- [13] Biega J, Kuzey E, Suchanek F M. Inside YAGO2s: A Transparent Information Extraction Architecture[C]. In Proceedings of the ACM International Conference on World Wide Web (WWW

2013), 2013: 325-328.

[14] Mahdisoltani F, Biega J, Suchanek F M. Yago3: A knowledge Base from Multilingual Wikipedias[C]. In Proceedings of the 6th Biennial Conference on Innovative Data Systems Research (CIDR 2013), 2013.

[15] Xu B, Xu Y, Liang JQ, et al. CN-DBpedia: A never-ending Chinese knowledge extraction system. Proceedings of the 30th International Conference on Industrial, Engineering and Other Applications of Applied Intelligent Systems. Arras, France. 2017. 428-438.

[16] Sun C, Gan C, Nevatia R. Automatic concept discovery from parallel text and visual corpora[C]. IEEE International Conference on Computer Vision, 2015: 2596-2604.

[17] Fang Q, Xu C S, Sang J T, et al. Folksonomy-based visual ontology construction and its applications[J]. IEEE Transactions on Multimedia, 2016, 18(4): 702-713.

[18] Zhu Y K, Zhang C, Ré C, et al. Building a large-scale multimodal knowledge base system for answering visual queries[J]. arXiv e-print, 2015, arXiv: 1507. 05670.

[19] Lu C W, Krishna R, Bernstein M, et al. Visual relationship detection with language priors[C]. European Conference on Computer Vision, 2016: 852-869.

[20] Ferrada S, Bustos B, Hogan A. IMGpedia: a linked dataset with content-based analysis of Wikimedia images[C]. International Semantic Web Conference. Springer, Cham, 2017: 84-93.

[21] Liu Y, Li H, Garcia-Duran A, et al. MMKG: multi-modal knowledge graphs[C]. European Semantic Web Conference. Springer, Cham, 2019: 459-474.

[22] Wang M, Qi G, Wang H F, et al. Richpedia: A Comprehensive Multi-modal Knowledge Graph[M]. Semantic Technology. 2020.

[23] Song Xiaozhao, Zheng Xin, Li Zhixu, et al. Online encyclopedia table knowledge acquisition and fusion for knowledge base expansion[J]. Software Engineering, 2019(10):1-6.

[24] Xiao T, Hui L. Research Front Recognition Based on Multi-source Data Knowledge Fusion Method[J]. Journal of Modern Information, 2019, 039(008):29-36.

[25] Smirnov A, Levashova T. Knowledge fusion patterns: A survey[J]. Information Fusion, 2019, 52:31-40.

[26] Zheng, Yu. Methodologies for Cross-Domain Data Fusion: An Overview[J]. IEEE Transactions on Big Data, 2015, 1(1):16-34.

- [27] Xu C, Tao D, Xu C. A Survey on Multi-view Learning[J]. Computer Science, 2013: 2031-2038.
- [28] Ngiam J, Khosla A, Kim Ms et al. Multimodal deep learning [C]. Proceedings of the 28th International Conference on Machine Learning, Bellevue: ACM, 2011: 689-696.
- [29] Srivastava N, Salakhutdinov R. Multimodal Learning with Deep Boltzmann Machines[C]. In Advances in Neural Information Processing Systems, Lake Tahoe, Spain, 2012: 2222-2230.
- [30] Bhandari D, Paul S, Narayan A. Multimodal Data Fusion and Prediction of Emotional Dimensions Using Deep Neural Network[J]. 2019.
- [31] Menon A K, Surian D, Chawla S. Cross-modal retrieval: a pairwise classification approach[C]. In Proceedings of the 2015 SIAM international conference on data mining, 2015:199-210.
- [32] AKAHO S. A kernel method for canonical correlation analysis[C]. Proceedings of the international meeting of the psychometric society.,2001:263-269.
- [33] 张博, 郝杰, 马刚,等. 混合概率典型相关性分析[J]. 计算机研究与发展, 2015, 000(007):1463-1476.
- [34] Andrew G, Arora R, Bilmes J, et al. Deep canonical correlation analysis[C]. International conference on machine learning, 2013:1247-1255.
- [35] Huang X, Peng Y, Yuan M. Cross-modal common representation learning by hybrid transfer network[C]. The 26th International Joint Conference on Artificial. Melbourne, Australia, 2017: 1893-1900.
- [36] Mahadevan V, Wong C W, Pereira J C, et al. Maximum covariance unfolding: Manifold learning for bimodal data[C]. Advances in Neural Information Processing Systems. Granada, Spain, 2011:918-926.
- [37] Zhao L, Chen Z, Yang Y, et al. Incomplete multi-view clustering via deep semantic mapping[J]. Neurocomputing, 2018,275:1053-1062.
- [38] Jacobs D W, Daume H, Kumar A, et al. Generalized Multiview Analysis: A discriminative latent space[C]. 2012 IEEE Conference on Computer Vision and Pattern Recognition. IEEE Computer Society, 2012:2160-2167.
- [39] Rosipal R, Nicole Krämer. Overview and Recent Advances in Partial Least Squares[C]. Subspace, latent structure and feature selection. Bohinj, Slovenia: Springer, 2006:34-51.

- [40] Zhou, Long, Mou, et al. Multiview partial least squares[J]. Chemometrics and Intelligent Laboratory Systems, 2017:13-21.
- [41] Sharma A, Jacobs D W. Bypassing synthesis: PLS for face recognition with pose, low-resolution and sketch[C]. Computer Vision and Pattern Recognition (CVPR), IEEE, 2011:593-600.
- [42] Lin Y, Liu Z, Luan H, et al. Modeling Relation Paths for Representation Learning of Knowledge Bases[J]. Computer Science, 2015.
- [43] Sun Z, Hu W, Li C. Cross-Lingual Entity Alignment via Joint Attribute-Preserving Embedding[C]. International Semantic Web Conference. 2017.
- [44] 李霞,卢官明,闫静杰,等.多模态维度情感预测综述[J].自动化学报,2018,44(12):2142-2159.
- [45] 黄恒琪, 于娟, 廖晓,等.知识图谱研究综述[J]. 计算机系统应用, 2019, 28(06):3-14.
- [46] Xie R, Liu Z, Luan H, et al. Image-embodied Knowledge Representation Learning[J]. 2016.
- [47] 刘烨宸, 李华昱. 领域知识图谱研究综述[J]. 计算机系统应用, 2020, 029(006):1-12.
- [48] 梁晓婷. 国外搜索引擎知识图谱构建研究[J]. 科学技术创新,2018,(21):61-63.
- [49] Ji G L, Liu K, He S Z, et al. Knowledge graph completion with adaptive sparse transfer matrix[C]. AAAI Conference on Artificial Intelligence, 2016: 985-991.
- [50] 刘峤, 李杨, 段宏, 刘瑶, 秦志光. 知识图谱构建技术综述[J]. 计算机研究与发展, 2016, 53(03): 582-600.
- [51] Jiang S, Lowd D, Dou D. Learning to Refine an Automatically Extracted Knowledge Base Using Markov Logic[J]. 2012:912-917.
- [52] Galileo Namata, Stanley Kok, Lise Getoor. Collective Graph Identification.knowledge discovery and data mining.2011.
- [53] Memory A, Kimmig A, Bach S H, et al. Graph Summarization in Annotated Data Using Probabilistic Soft Logic[J]. In: Workshop on Uncertainty Reasoning for the Semantic Web (URSW, 2012, 900:75-86.
- [54] Zhao B, Rubinstein B I P, Gemmell J, et al. A Bayesian approach to discovering truth from conflicting sources for data integration[J]. Proceedings of the Vldb Endowment, 2012, 5(6):550-561.
- [55] Zhao B, Han J. A Probabilistic Model for Estimating Real-valued Truth from Conflicting Sources[J]. Proc.of Intl.workshop on Quality in Databases.
- [56] Xiao H, Gao J, Li Q, et al. Towards Confidence in the Truth: A Bootstrapping based Truth

Discovery Approach[C]. ACM SIGKDD International Conference on Knowledge Discovery and Data Mining. ACM, 2016.

[57] Wang Y, Ma F, Gao J. Efficient Knowledge Graph Validation via Cross-Graph Representation Learning[J]. 2020.

[58] Mirhosseini M, Seo J. Wiki'like: Making Use of Knowledge Graphs in a Classroom[C]. Companion of the 2018 ACM Conference on Computer Supported Cooperative Work and Social Computing. 2018.

[59] 杜嘉, 刘思含, 李文浩等. 基于深度学习的煤矿领域实体关系抽取研究[J]. 智能计算机与应用, 2019, 9(1): 114-118.

[60] 刘燕. 医学百科知识图谱构建[J]. 中华医学图书情报杂志, 2018, 27(6): 28-34.

[61] Liu Q, Li Y, Duan H, et al. Knowledge graph construction techniques. Journal of Computer Research and Development, 2016, 53(3): 582-600.

[62] Hossain M, Butler P, Boedihardjo A, et al. Story telling in entity networks to support intelligence analysts[C]. Proc of the 18th ACM SIGKDD Int Conf on Knowledge Discovery and Data Mining. New York: ACM, 2012: 1375-1383.

[63] Wen C, Liu Y, Gu J, et al. E-SKB: A Semantic Knowledge Base for Emergency[M]. Knowledge Graph and Semantic Computing: Semantic, Knowledge, and Linked Big Data. Springer Singapore, 2016: 196-202.

[64] 周莉娜, 洪亮, 高子阳. 唐诗知识图谱的构建及其智能知识服务设计[J]. 图书情报工作, 2019, 63(02): 24-33.

[65] 陈涛, 刘炜, 单蓉蓉, 朱庆华. 知识图谱在数字人文中的应用研究[J]. 中国图书馆学报, 2019, 45(06): 34-49.

[66] Zhang X, Sun X, Xie C, et al. From vision to content: Construction of Domain-specific Multi-modal Knowledge Graph[J]. IEEE Access, 2019, PP(99): 1-1.

[67] 周晶, 吴军华, 陈佳, 等. 基于条件随机域 CRF 模型的文本信息抽取[J]. 计算机工程与设计, 2008, 29(023): 6094-6097.

[68] 翟社平, 段宏宇, 李兆兆. 基于 BILSTM_CRF 的知识图谱实体抽取方法[J]. 计算机应用与软件, 2019, 36(05): 269-274.

[69] Zeng, Dao Jian, et al. "Relation classification via convolutional deep neural network."

Proceedings of COLING 2014, the 25th International Conference on Computational Linguistics: Technical Papers. 2014.

[70] Zeng, Dao Jian, et al. "Distant supervision for relation extraction via piecewise convolutional neural networks." Proceedings of the 2015 Conference on Empirical Methods in Natural Language Processing. 2015.

[71] Li P, Mao K. Knowledge-oriented convolutional neural network for causal relation extraction from natural language texts[J]. Expert Systems with Application, 2019, 115:512-523.

[72] Phi V T, Santoso J, Tran V H, et al. Distant Supervision for Relation Extraction via Piecewise Attention and Bag-Level Contextual Inference[J]. IEEE Access, 2019, PP(99):1-1.

[73] Xu J, Kim S, Song M, et al. Building a PubMed knowledge graph[J]. Entific Data, 2020, 7(1).

[74] Zhao D, Chang Z, Guo S. A multimodal fusion approach for image captioning[J]. Neurocomputing, 2019, 329:476-485.

[75] PENG Yuxin, QI Jinwei. CM-GANs: Cross-modal generative adversarial networks for common representation learning[J]. Multimedia, 2019, 15(1):1-13.

致谢

一转眼两年半的时光已经过去，我也即将告别美好而青春的校园生活，在北方民族大学就读的研究生生涯可以说是我人生中最难忘的一段经历，在这里，我不仅有幸跟随一位认真负责的老师，还遇到了志同道合的同学，在学校经历的一切都让我觉得我是如此幸运。

首先，我要感谢我的导师王海荣老师，从开学伊始王老师对我耐心细致的指明研究方向，研究过程中每一个知识点对我进行的悉心指导，最后论文撰写过程中，一遍又一遍的为我进行指导，甚至常常忙碌到深夜。是她孜孜不倦的教诲驱散了我对知识的迷茫，她无微不至的关心让我在学校的生活中倍感温暖，是她严肃活泼的治学态度让我在整个研究生期间受益匪浅。同时，王老师的治学精神和工作态度也在深深地影响着我，让我真正体会到了严谨、认真的态度在工作和学习中的重要性。另外我要感谢我的企业导师邹新德，感谢邹老师给我提供了更多的机会和机遇，拓宽了我的视野和发展前景。我今天能够顺利毕业离不开你们每一个字的指导和教诲。希望老师们在今后的工作中，事事顺利，身体健康。

其次，我要感谢我的同门，在学习，我们互相帮助，互相监督，互相促进，遇到困难时，你们也是我的良师益友。在生活中，我们互相扶持，彼此鼓舞，彼此关心，是你们让我感受到了一个集体给人的无穷力量和温暖。两年半的研究生生涯能和你们一起并肩度过，你们每个人的优秀特质令我感到由衷的骄傲和自豪。希望大家不论在今后的求学还是工作的道路上，都能乘风破浪，披荆斩棘，最终收获梦想，获得成功。

最后，我要感谢所有给予过我帮助的老师 and 同学们，是你们照亮了我两年半求学生涯的路，是你们的陪伴给了我无穷无尽的希望和动力，是你们让我克服了一个又一个苦难和阻碍，感谢你们在我的生命中闪闪发光。我真诚的祝愿你们在今后的路途中前程似锦。

多少句感谢也说不清我的谢意，多少句留恋也道不明我的不舍。在离开熟悉的校园之后，你们的意志将陪伴着我在今后的人生道路上攻坚克难，成就自己更加美好的人生。

个人简介

刘昱然（1996-），女，汉族，河南省驻马店市人。2013 年 9 月至 2017 年 6 月就读于黄淮学院，并取得工学学士学位；2018 年 9 月至今就读于北方民族大学计算机科学与工程学院，攻读工程硕士学位，攻读研究生期间主要从事知识工程和自然语言处理相关工作。

攻读硕士学位期间发表的论文如下：

（1）刘昱然,王海荣,杜锦丰,张卓彪.基于标签对齐的多模态知识融合方法研究[J],MBE 2020（正在审稿）；

（2）刘昱然,王海荣,基于神经网络的关系抽取方法研究[J]计算机应用研究（正在审稿）。

攻读硕士学位期间参与的课题如下：

（1）宁夏高等学校一流学科建设（电子科学与技术学科）（No. NXYLXK2017A07）；

（2）北方民族大学国家级大学生创新项目：基于人工智能的智能党务管理平台的设计（No.2020-TDXM-034）；

（3）北方民族大学研究生创新项目：多模态党建知识图谱构建方法与应用研究（No.YCX19078）。